



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών
Εξάμηνο 7ο: Μηχανική Μάθηση

1^η Ομάδα Ασκήσεων

Ημερομηνία Παράδοσης: 15/11/2024

Γιάννης Πολυχρονόπουλος, ε121089

Aσκηση 1.1

(a)

Έχουμε $y_i = \underline{x}_i^T w + \varepsilon_i$ Μηρη
Διανομής $\underline{y} = \underline{X}\underline{w} + \underline{\varepsilon}$, με $\varepsilon = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N]^T$

Άρα $\underline{\varepsilon} \sim N(\underline{\mu}, \Sigma)$, όπου $\underline{\mu} = \underline{0} = E[\underline{\varepsilon}]$ και $\varepsilon_i \sim N(0, \sigma^2)$ και $\Sigma = \sigma^2 I_N$ καθώς $Cov(\underline{\varepsilon}) = \Sigma$

και $Cov(\varepsilon_i, \varepsilon_j) = 0$ με $i \neq j$ καθώς τα σφαλματικά μέτραζό των δίνουν ανεξάρτητα, και $Cov(\varepsilon_i, \varepsilon_i) = \sigma^2 \neq 0$.

Έχουμε το \underline{y} να δίνει αδροτορικά εντός σταδιού διανομής $N(\underline{\mu}_y, \Sigma_y)$ και τα διανομής σφαλμάτων $\underline{\varepsilon} \sim N(\underline{0}, \sigma^2 I_N)$. Συνεπώς, το \underline{y} θα αποδίδει πολυτελεία και ακραία σφαλματική.

Άρα $\underline{y} \sim N(\underline{\mu}_y, \Sigma_y)$, με $\underline{\mu}_y = E[\underline{y}] = E[\underline{X}\underline{w} + \underline{\varepsilon}] = E[\underline{X}\underline{w}] + E[\underline{\varepsilon}]$

$$\Rightarrow \underline{\mu}_y = \underline{X}\underline{w} + \begin{bmatrix} E[\varepsilon_1] \\ \vdots \\ E[\varepsilon_N] \end{bmatrix} = \underline{X}\underline{w} + \underline{0} = \underline{X}\underline{w}$$

Και $\Sigma_y = Cov(\underline{y}) = Cov(\underline{X}\underline{w} + \underline{\varepsilon}) = Cov(\underline{\varepsilon}) = \sigma^2 I_N$

Άρα $\underline{y} \sim N(\underline{X}\underline{w}, \sigma^2 I_N) \rightarrow P(\underline{y}) = \frac{1}{(2\pi)^{N/2} \cdot \sigma} \cdot \exp\left(-\frac{1}{2} (\underline{y} - \underline{X}\underline{w})^T \sigma^2 (\underline{y} - \underline{X}\underline{w})\right)$

(b) Ορίζουμε το μέσος ελαχιστών τετραγώνων:

$$J(w) = \|\underline{\varepsilon}\|^2 = \|\underline{y} - \underline{X}\underline{w}\|^2 = (\underline{y} - \underline{X}\underline{w})^T (\underline{y} - \underline{X}\underline{w}) = \underline{y}^T \underline{y} - \underline{w}^T \underline{X}^T \underline{y} - \underline{y}^T \underline{X} \underline{w}$$

Ιδιοτητα $\Rightarrow J(w) = \underline{y}^T \underline{y} - 2\underline{w}^T \underline{X} \underline{y} + \underline{w}^T \underline{X}^T \underline{X} \underline{w}$, Τηρούμεσση μα να δρουμε σε ελαχιστ.

$$\text{ATB} = B^T A \Rightarrow \nabla J(w) = 0 \Rightarrow -2\underline{X}^T \underline{y} + 2\underline{X}^T \underline{X} \underline{w} = 0 \Rightarrow \underline{\hat{w}} = (\underline{X}^T \underline{X})^{-1} \underline{X}^T \underline{y}$$

rank(X)=p+1 απα αντιστρέψιμος

(8) Θέλουμε να δείξουμε ότις $E[\hat{w}] = \underline{w}$

$$\text{Έχουμε: } E[\hat{w}] = E[(X^T X)^{-1} \cdot X^T \cdot \underline{y}] = E[(X^T X)^{-1} \cdot X^T (X\underline{w} + \underline{\varepsilon})]$$

$$\Rightarrow E[\hat{w}] = \underbrace{E[(X^T X)^{-1} \cdot X^T \cdot \underline{X} \cdot \underline{w}]}_{\text{IN } X(\text{pt1})} + (X^T X)^{-1} \cdot X^T \cdot \underline{\varepsilon} = \underline{w} + (X^T X)^{-1} \cdot X^T E[\underline{\varepsilon}]$$

Έχουμε $\hat{w} = \underline{w} + (X^T X)^{-1} \cdot X^T \underline{\varepsilon}$ (1)

• Υπολογισμός $Cov(\hat{w})$:

$$\begin{aligned} \text{Άριθμος } Cov(\hat{w}) &= E[(\hat{w} - E[\hat{w}])(\hat{w} - E[\hat{w}])^T] \\ \Rightarrow Cov(\hat{w}) &= E[(\hat{w} - \underline{w})(\hat{w} - \underline{w})^T] \quad \text{(1)} \end{aligned}$$

• Υπολογισμός του $Cov(\hat{w})$: $Cov(\hat{w}) \stackrel{(1)}{=} Cov(\underline{w} + (X^T X)^{-1} \cdot X^T \cdot \underline{\varepsilon})$, Τύχη: $Cov(AX + a) = A \cdot Cov(X) \cdot A^T$

$$\Rightarrow Cov(\hat{w}) = (X^T X)^{-1} X^T \cdot Cov(\underline{\varepsilon}) \cdot X (X^T X)^{-1}$$

$$\Rightarrow Cov(\hat{w}) = (X^T X)^{-1} X^T \sigma^2 I_N \cdot X (X^T X)^{-1} = \sigma^2 \underbrace{(X^T X)^{-1} X^T X}_{I} \cdot (X^T X)^{-1} \quad \text{ΗC } A, a \text{ ουδεποτί}$$

$$\Rightarrow Cov(\hat{w}) = \sigma^2 \cdot (X^T X)^{-1}$$

Άρα $\hat{w} \sim N(\underline{w}, \sigma^2 (X^T X)^{-1})$

(5) Έχουμε την οχέαν $\hat{y}_i = x_i^T \cdot \hat{w}$ άρα $\hat{y} = X \cdot \hat{w}$ ~~από~~ το \hat{y} αντιστοιχεί με την \underline{y}

$$E[\hat{y}] = E[X \cdot \hat{w}] = X \cdot E[\hat{w}] = X \cdot \underline{w} \Rightarrow E[\hat{y}] = X \cdot \underline{w}$$

$$Cov(\hat{y}) = Cov(X \cdot \hat{w}) = X \cdot Cov(\hat{w}) \cdot X^T = X \sigma^2 (X^T X)^{-1} X^T \Rightarrow Cov(\hat{y}) = \sigma^2 X (X^T X)^{-1} X^T$$

Άρα $\hat{y} \sim N(X\underline{w}, \sigma^2 X (X^T X)^{-1} X^T)$. Στη συνέχεια θα δείξουμε ότις \hat{y} είναι προβολή του y στο χώρο στοιχυών των X .

• Απλείτε να δείξουμε ότι: $\hat{y} = P_X(y) = X(X^T X)^{-1} X^T \cdot y$

Πράγματι: $\hat{y} = X \cdot \hat{w} \stackrel{?}{=} X(X^T X)^{-1} X^T \cdot y = P_X(y)$

(E) Έχουμε $\hat{\epsilon}_i = y_i - \hat{y}_i \xrightarrow{\text{Δηλωση}} \hat{\epsilon} = \underline{y} - \hat{\underline{y}}$, y, \hat{y} ανορθόδοξα μαρκινά
κατανομής από τα οποία προέρχεται $\hat{\epsilon}$

$$\bullet E[\hat{\epsilon}] = E[\underline{y} - \hat{\underline{y}}] = E[\underline{y}] - E[\hat{\underline{y}}] = X_w - X_w = 0$$

$$\bullet \text{Cov}(\hat{\epsilon}) = \text{Cov}(\underline{y} - \hat{\underline{y}}) = \text{Cov}(X_w + \epsilon - X(X^T X)^{-1} X^T (X_w + \epsilon))$$

$$\Rightarrow \text{Cov}(\hat{\epsilon}) = \text{Cov}(X_w + \epsilon - X(X^T X)^{-1} X^T X_w - X(X^T X)^{-1} X^T \epsilon)$$

$$\Rightarrow \text{Cov}(\hat{\epsilon}) = \text{Cov}(X_w + \epsilon - Xw - X(X^T X)^{-1} X^T \epsilon) \rightarrow \text{δεκτώ } X(X^T X)^{-1} X^T = P$$

$$\Rightarrow \text{Cov}(\hat{\epsilon}) = \text{Cov}((I-P)\epsilon) = (I-P) \cdot \text{Cov}(\epsilon) \cdot (I-P)^T = \sigma^2 (I-P)(I-P)^T$$

$$\boxed{\hat{\epsilon} = (I-P)\epsilon} \Rightarrow \text{Cov}(\hat{\epsilon}) = \sigma^2 (I-P)(I^T - P^T) \stackrel{P^T = P}{=} \sigma^2 (I-P)(I-P)$$

$$\Rightarrow \text{Cov}(\hat{\epsilon}) = \sigma^2 (I \cdot I - IP - PI + P \cdot P) = \sigma^2 (I - P - P + P \cdot P)$$

$$\textcircled{*} P \cdot P = X \cdot \underbrace{(X^T X)^{-1} X^T}_{V_1} \cdot X \cdot (X^T X)^{-1} X^T = X(X^T X)^{-1} X^T = P$$

$$\textcircled{**} \Rightarrow \text{Cov}(\hat{\epsilon}) = \sigma^2 (I-P) \quad \text{από } \hat{\epsilon} \sim N(0, \sigma^2 (I-P))$$

$$\bullet \text{Θα δείξουμε ότι } \hat{\epsilon}^T \cdot \hat{\epsilon} = \underline{y}^T (I-P) \underline{y}$$

$$\rightarrow \hat{\epsilon}^T \cdot \hat{\epsilon} = (\underline{y} - \hat{\underline{y}})^T (\underline{y} - \hat{\underline{y}}) = \cancel{(\underline{y} - \hat{\underline{y}})^T \cancel{(\underline{y} - \hat{\underline{y}})}} (\underline{y} - Py)^T (\underline{y} - Py)$$

$$\Rightarrow \hat{\epsilon}^T \cdot \hat{\epsilon} = (\underline{y}^T - \underline{y}^T P^T) \cdot (\underline{y} - Py) = (\underline{y}^T (I - P^T)) \cdot \cancel{(I - P)} \cancel{\underline{y}}$$

$$\stackrel{P^T = P}{\Rightarrow} \hat{\epsilon}^T \cdot \hat{\epsilon} = \underline{y}^T \underbrace{(I - P)(I - P)}_{I^2 - IP - PI + P^2 = P(I - P)} \underline{y} = \underline{y}^T (I - P) \underline{y}$$

$I^2 - IP - PI + P^2 = P(I - P)$, οπώς δείχνεται και προηγουμένως

Άσκηση 1.2

Άσκηση 1.2 Το διανυσματικό μέσο $\underline{\mu}$ είναι $\underline{\mu} = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}$, και το κορινθιακό ρήσον Σ είναι $\Sigma = \begin{bmatrix} \text{cov}(x,x) & \text{cov}(x,y) \\ \text{cov}(y,x) & \text{cov}(y,y) \end{bmatrix} = \begin{bmatrix} \sigma_x^2 & \rho_{x,y} \cdot \sigma_x \cdot \sigma_y \\ \rho_{x,y} \cdot \sigma_x \cdot \sigma_y & \sigma_y^2 \end{bmatrix} = \begin{bmatrix} 9 & 7,2 \\ 7,2 & 16 \end{bmatrix}$

$$\mu = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \text{ και } \Sigma = \begin{bmatrix} \text{cov}(x,x) & \text{cov}(x,y) \\ \text{cov}(y,x) & \text{cov}(y,y) \end{bmatrix} = \begin{bmatrix} \sigma_x^2 & \rho_{x,y} \cdot \sigma_x \cdot \sigma_y \\ \rho_{x,y} \cdot \sigma_x \cdot \sigma_y & \sigma_y^2 \end{bmatrix} = \begin{bmatrix} 9 & 7,2 \\ 7,2 & 16 \end{bmatrix}$$

$$P_{X,Y} = \frac{\text{cov}(x,y)}{\sigma_x \cdot \sigma_y}$$

$$\text{Άρα } p(\underline{w}) = \frac{1}{(2\pi)^{2/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (\underline{x}-\underline{\mu})^T \cdot \Sigma^{-1} \cdot (\underline{x}-\underline{\mu})\right)$$

Από το wikipedia στη 2-D πουράρεται τιμώντας τιμώντας γίνεται:

$$p(x,y) = \frac{1}{2\pi \cdot \sigma_x \cdot \sigma_y \sqrt{1-\rho^2}} \exp\left(-\frac{1}{2[1-\rho^2]} \left[\left(\frac{x-\mu_x}{\sigma_x}\right)^2 - 2\rho \left(\frac{x-\mu_x}{\sigma_x}\right) \left(\frac{y-\mu_y}{\sigma_y}\right) + \left(\frac{y-\mu_y}{\sigma_y}\right)^2 \right]\right)$$

$$\text{Άρα } p(x,y) = \frac{1}{19.2\pi} \cdot \exp\left(-\frac{1}{1.28} \left[\left(\frac{x-5}{3}\right)^2 - 1.2 \left(\frac{x-5}{3}\right) \left(\frac{y-10}{5}\right) + \left(\frac{y-10}{5}\right)^2 \right]\right)$$

(B) Από διαφάνειες έχουμε τις $(x_1, x_2 = a) \sim N(\hat{\mu}, \hat{\Sigma})$, με

$$\hat{\mu} = \mu_1 + 2_{12} \Sigma_{22}^{-1} (a - \mu_2) \quad \text{και} \quad \hat{\Sigma} = \Sigma_{11} - 2_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

Για 2-D από το wikipedia οι πράξεις αποτυπώνονται και έχουμε:

$$\begin{aligned} y|x=6 &\sim N\left(\mu_y + \frac{\sigma_y}{\sigma_x} \cdot \rho(a - \mu_x), (1 - \rho^2) \sigma_y^2\right) \\ &\sim N\left(10 + \frac{4}{3} \cdot 0,6(6-5), (1-0,6^2) \cdot 4^2\right) \\ &\sim N(10,8, 10,24) \end{aligned}$$

$$\text{Άρα } p(y|x=6) = \frac{1}{10,24 \cdot 2\pi} \exp\left(-\frac{(y-10,8)^2}{20,48}\right)$$

$$\text{Για } p(y>10|x=6) \text{ υπολογίζουμε το } P(y>10|x=6) = \int_{10}^{\infty} p(y>10|x=6) dy$$

Η python script υπολογίζει $P(y>10|x=6) = 0.5987$

$$\begin{aligned}
 (8) \text{ Aντιστροφή } x|y=9 &\sim N\left(\mu_x + \frac{\delta_x}{\delta_y} \cdot p(a - \mu_y), (1-p^2)\sigma_x^2\right) \\
 &\sim N\left(5 + \frac{3}{4} \cdot 0,6(9-10), (1-0,6^2) \cdot 9\right) \\
 &\sim N(4,55, 5,76)
 \end{aligned}$$

Aπα $p(x|y=9) = \frac{1}{\sqrt{2 \pi \cdot 5,76}} \exp\left(-\frac{(x-4,55)^2}{2 \cdot 5,76}\right)$

Για $P(x > 5 | y=9) = \int_5^{100} p(x|y=9) dx = 0,4256$ με Python script

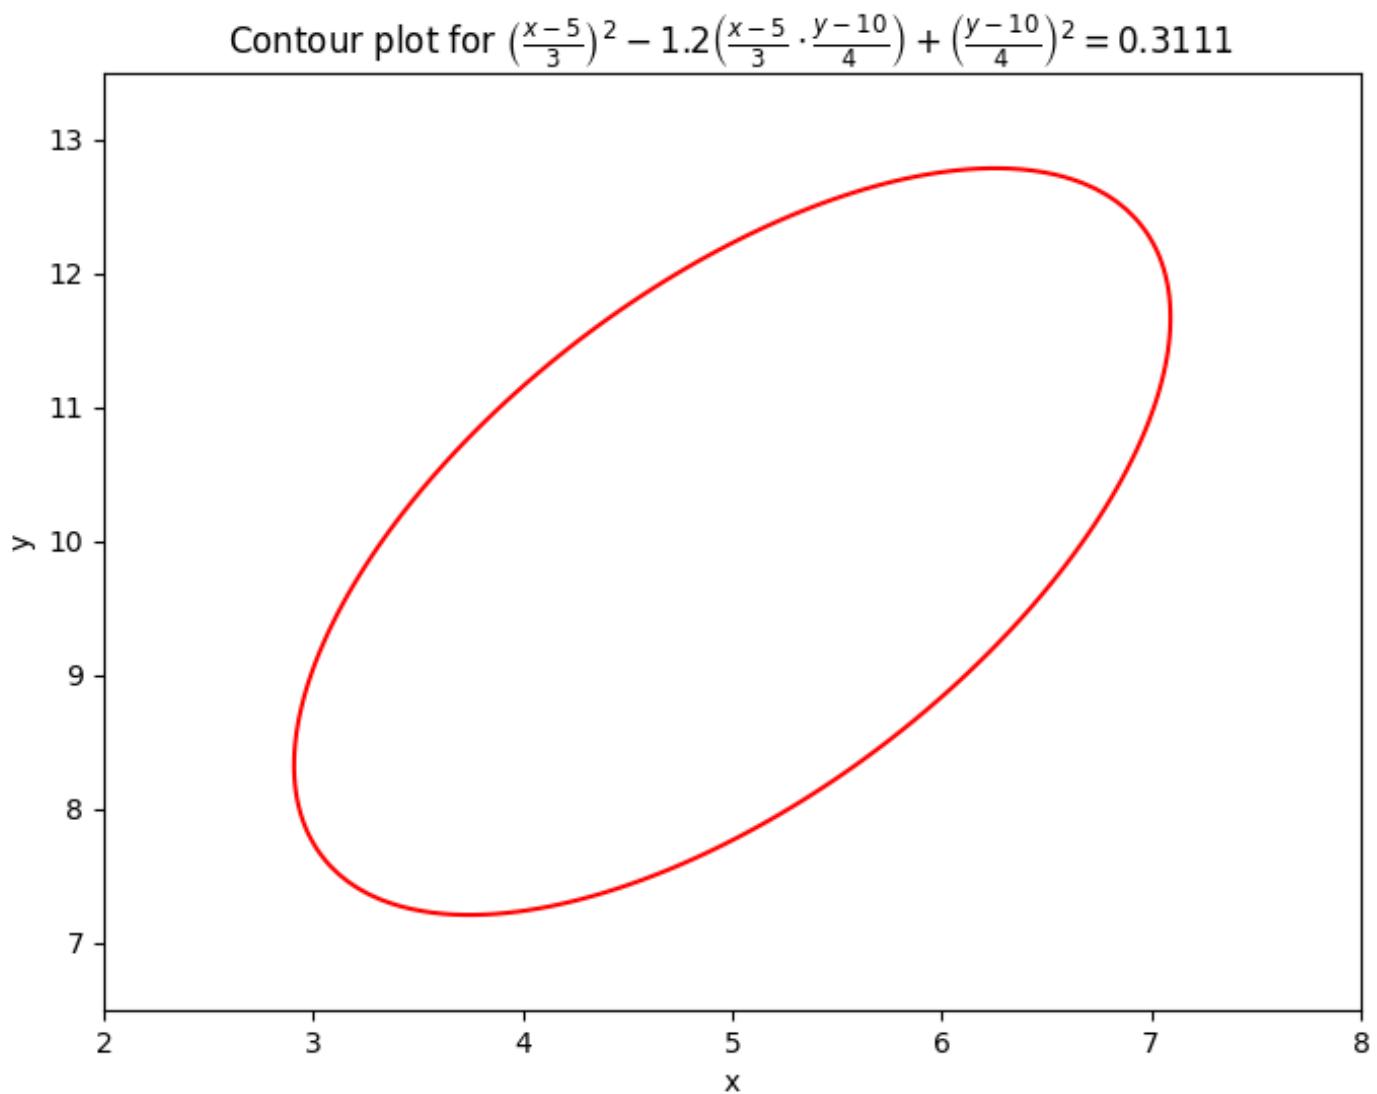
(5) Χρησης Python Script. Για $(x,y) = (6,12)$: $p(x,y) = \frac{0,030119}{0,013} = 0,013$

Aπα Ιωδραφής: $\frac{1}{19,2\pi} \cdot \exp\left(-\frac{1}{1,28} \left[\left(\frac{x-5}{3}\right)^2 - 1,2 \left(\frac{x-5}{3}\right) \left(\frac{y-10}{4}\right) + \left(\frac{y-10}{4}\right)^2\right]\right) = \frac{0,030119}{0,013}$

$\boxed{(*) \left(\frac{x-5}{3}\right)^2 - 1,2 \left(\frac{x-5}{3}\right) \left(\frac{y-10}{4}\right) + \left(\frac{y-10}{4}\right)^2 = \frac{0,030119}{0,013}}$

Άσκηση 1.2, Ερώτημα Δ

Σχεδιασμός της ισοσταθμικής καμπύλης:



Ο κώδικας που χρησιμοποιήθηκε είναι ο ακόλουθος:

```
import numpy as np
import matplotlib.pyplot as plt
# Define the function based on the given equation
def contour_function(x, y):
    term1 = ((x - 5) / 3) ** 2
    term2 = -1.2 * ((x - 5) / 3) * ((y - 10) / 5)
    term3 = ((y - 10) / 5) ** 2
    return term1 + term2 + term3

# Set up the grid of x and y values
x = np.linspace(-5, 15, 400)
y = np.linspace(0, 20, 400)
X, Y = np.meshgrid(x, y)

# Calculate Z values on the grid
Z = contour_function(X, Y)
# Define the contour level based on the given constant
contour_level = 0.111111111113
# Plotting
plt.figure(figsize=(8, 6))
contour = plt.contour(X, Y, Z, levels=[contour_level], colors='red')
plt.xlabel('x')
plt.ylabel('y')
plt.title(r'Contour Plot')
plt.xlim([2.5, 7.5])
plt.ylim([7.5, 12.5])
plt.show()
```

Για τα προηγούμενα ερωτήματα οι υπολογισμοί έγιναν με τον ακόλουθο κώδικα

```
from scipy.stats import norm
from math import sqrt
# (b)
y = 10 # y > 10
mean_y_given_x = 10.8
std_y_given_x = sqrt(10.24)
prob = norm.sf(y, loc=mean_y_given_x, scale=std_y_given_x)
print(f"Probability is : {prob:.4f}")
# (c)
x = 5 # x > 5
mean_y_given_x = 4.55
std_y_given_x = sqrt(5.76)
prob = norm.sf(x, loc=mean_y_given_x, scale=std_y_given_x)
print(f"Probability is : {prob:.4f}")
```

Axiom 1.3

(α) Ελεγχόμενη με υποθέσεις τη $P(w_i | \underline{x})$ για $i=1,2,3$ και έρχομε $P(w_i)$ και

Από την θεωρία Bayes $P(w_i | \underline{x}) = \frac{P(\underline{x} | w_i) \cdot P(w_i)}{P(\underline{x})}$ της πιθανότητας $\underline{x} | w_i$

$$\text{όπου } P(\underline{x}) = \sum_{i=1}^3 P(\underline{x} | w_i) \cdot P(w_i), \text{ από την επόμενη σύντομη πιθανότητα.}$$

Μέτων Python υποθέσεις της πιθανότητας $P(w_i | \underline{x})$.

$$\text{Επαρκέ: } P(w_1 | \underline{x}) = 0,0618, P(w_2 | \underline{x}) = 0,5864, P(w_3 | \underline{x}) = 0,3518$$

(β) Διαφύγει με την επίσημη Bayes το $\underline{x} = (3,5)$ την πιθανότητα στην κατηγορία w_2 ; Τίποι αποτελεί την πιθανότητα posterior πιθανότητας για το \underline{x}

(γ) Τια τις κατηγορίες αποφάσισε πιθανότητα να δοθεί πιοτε πιοτε στην οι πιθανότητες $P(w_i | \underline{x})$

- Για w_1, w_2 : $P(w_1 | \underline{x}) = P(w_2 | \underline{x}) \Rightarrow P(\underline{x} | w_1) \cdot P(w_1) = P(\underline{x} | w_2) \cdot P(w_2)$ ①

- Για w_2, w_3 : $P(w_2 | \underline{x}) = P(w_3 | \underline{x}) \Rightarrow P(\underline{x} | w_2) \cdot P(w_2) = P(\underline{x} | w_3) \cdot P(w_3)$ ②

- Για w_1, w_3 : $P(w_1 | \underline{x}) = P(w_3 | \underline{x}) \Rightarrow P(\underline{x} | w_1) \cdot P(w_1) = P(\underline{x} | w_3) \cdot P(w_3)$ ③

$$\text{Για } x = (x_1, x_2) \cdot P(x|w_1) = \frac{1}{2\pi \cdot 1 \cdot 1 \cdot \sqrt{1-0,5^2}} \exp \left(-\frac{1}{2(1-0,5^2)} \left[\left(\frac{x_1-3}{1}\right)^2 - 2 \cdot 0,5 \cdot \left(\frac{x_1-3}{1}\right) \left(\frac{x_2-2}{1}\right) + \left(\frac{x_2-2}{1}\right)^2 \right] \right)$$

(Χρησημοποιούμετε τις τιμές που έδωσε στην αρχή για να εργάστηκε (2))

$$\cdot P(x|w_2) = \frac{1}{2\pi \cdot 1 \cdot 1 \cdot \sqrt{1-0,5^2}} \exp \left(-\frac{1}{2(1-0,5^2)} \left[\left(\frac{x_1-4}{1}\right)^2 - 2 \cdot 0,5 \cdot \left(\frac{x_1-4}{1}\right) \left(\frac{x_2-3}{1}\right) + \left(\frac{x_2-3}{1}\right)^2 \right] \right)$$

$$\cdot P(x|w_3) = \frac{1}{2\pi \cdot 1 \cdot 1 \cdot \sqrt{1-0,5^2}} \exp \left(-\frac{1}{2(1-0,5^2)} \left[\left(\frac{x_1-6}{1}\right)^2 - 2 \cdot 0,5 \cdot \left(\frac{x_1-6}{1}\right) \left(\frac{x_2-7}{1}\right) + \left(\frac{x_2-7}{1}\right)^2 \right] \right)$$

Aπων (1) $\Rightarrow \exp \left(-\frac{1}{1,5} \left[(x_1-3)^2 - (x_1-3)(x_2-2) + (x_2-2)^2 \right] \right) \cdot P(w_1) = \exp \left(-\frac{1}{1,5} \left[(x_1-4)^2 - (x_1-4)(x_2-3) + (x_2-3)^2 \right] \right) \cdot P(w_2)$

$$\ln \Rightarrow -\frac{1}{1,5} \left[(x_1-3)^2 - (x_1-3)(x_2-2) + (x_2-2)^2 - (x_1-4)^2 + (x_1-4)(x_2-3) - (x_2-3)^2 \right] = \ln \left(\frac{P(w_2)}{P(w_1)} \right)$$

$$\Rightarrow (x_1^2 - 6x_1 + 9) - (x_1x_2 + 2x_1 - 3x_2 - 6) + (x_2^2 + 4x_2 + 4) - (x_1^2 - 8x_1 + 16) + (x_1x_2 - 3x_1 - 4x_2 - 12) - (x_2^2 - 6x_2 + 9) = \ln \left(\frac{0,5}{0,2} \right)$$

$$\Rightarrow 9 + 3x_2 + 6 + 4 - 16 - 3x_1 + 12 + 6x_2 - 9 = (-1,5) \cdot \ln \left(\frac{0,5}{0,2} \right)$$

$$\Rightarrow -3x_1 + 9x_2 + 6 = (-1,5) \cdot \ln(2,5)$$

$$\Rightarrow \boxed{3x_1 - 9x_2 = 1,5 \ln(2,5) + 6} \text{ μα } w_1, w_2$$

(2) $\Rightarrow \boxed{x_2 = 5 - \frac{1,5}{6} \cdot \ln \left(\frac{0,3}{0,2} \right)}$ μα w_2, w_3

(3) $\Rightarrow \boxed{-3x_1 + 15x_2 = 24 - 1,5 \ln \left(\frac{0,3}{0,2} \right)}$ μα w_1, w_3

Ασκηση 1.3

(a) Python Code για το υπολογισμό πιθανοτήτων

```
import numpy as np

from scipy.stats import multivariate_normal

# Given data
mu1 = np.array([3, 2])
mu2 = np.array([4, 3])
mu3 = np.array([6, 7])
cov_matrix = np.array([[1, 0.5], [0.5, 1]])
priors = np.array([0.2, 0.5, 0.3])
x = np.array([3, 5])

# Calculate likelihoods
p_x_given_w1 = multivariate_normal.pdf(x, mean=mu1, cov=cov_matrix)
p_x_given_w2 = multivariate_normal.pdf(x, mean=mu2, cov=cov_matrix)
p_x_given_w3 = multivariate_normal.pdf(x, mean=mu3, cov=cov_matrix)

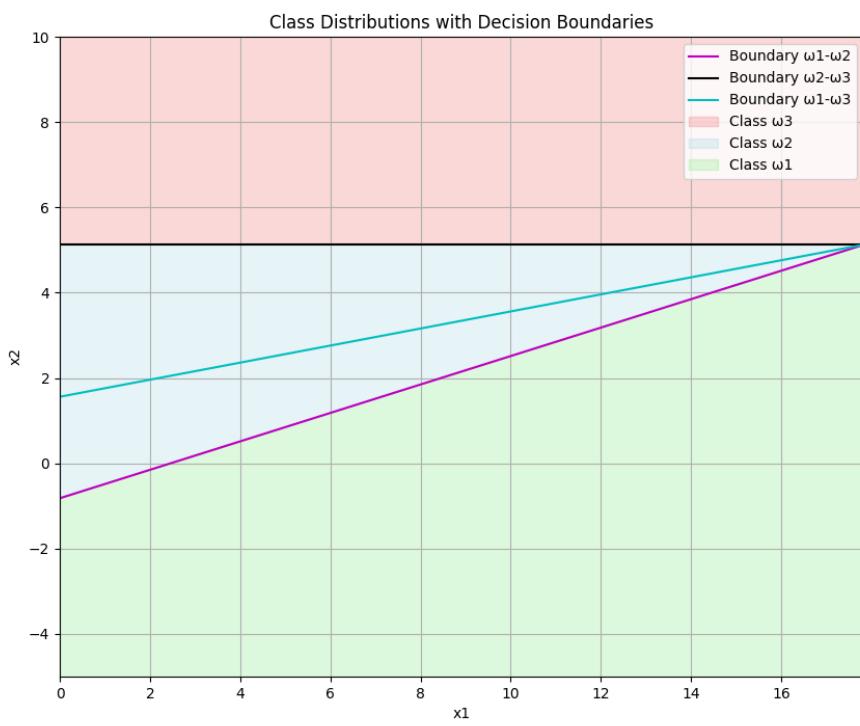
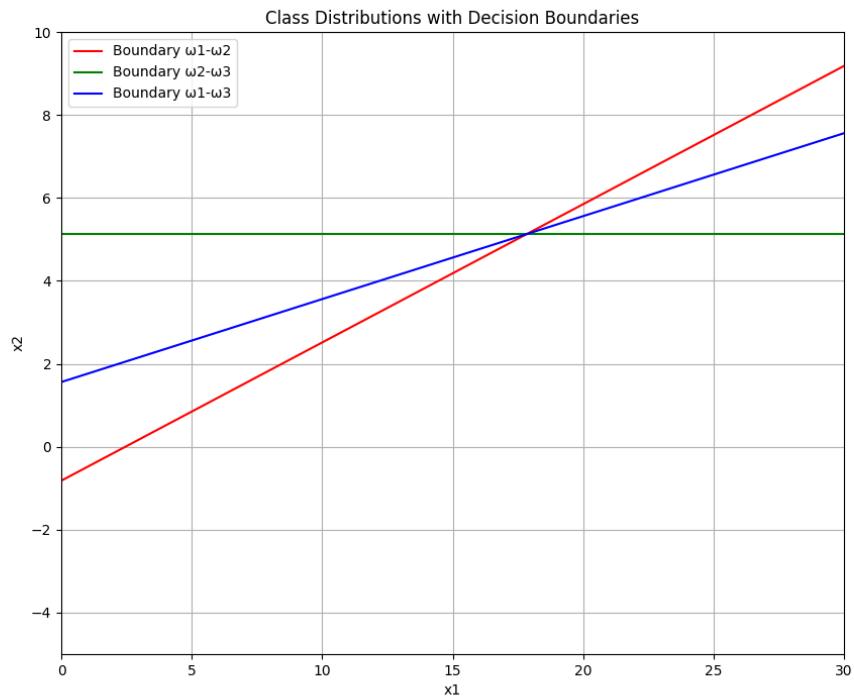
# Calculate posteriors using Bayes' rule
evidence = p_x_given_w1 * priors[0] + p_x_given_w2 * priors[1] +
p_x_given_w3 * priors[2]
p_w1_given_x = (p_x_given_w1 * priors[0]) / evidence
p_w2_given_x = (p_x_given_w2 * priors[1]) / evidence
p_w3_given_x = (p_x_given_w3 * priors[2]) / evidence

print("Posterior probabilities:")
print(f"P(w1 | x) = {p_w1_given_x:.4f}")
print(f"P(w2 | x) = {p_w2_given_x:.4f}")
print(f"P(w3 | x) = {p_w3_given_x:.4f}")
```

Output:

```
Posterior probabilities:
P(w1 | x) = 0.0618
P(w2 | x) = 0.5864
P(w3 | x) = 0.3518
```

(γ) Παρακάτω φαίνονται οι καμπύλες απόφασης που βρήκαμε.

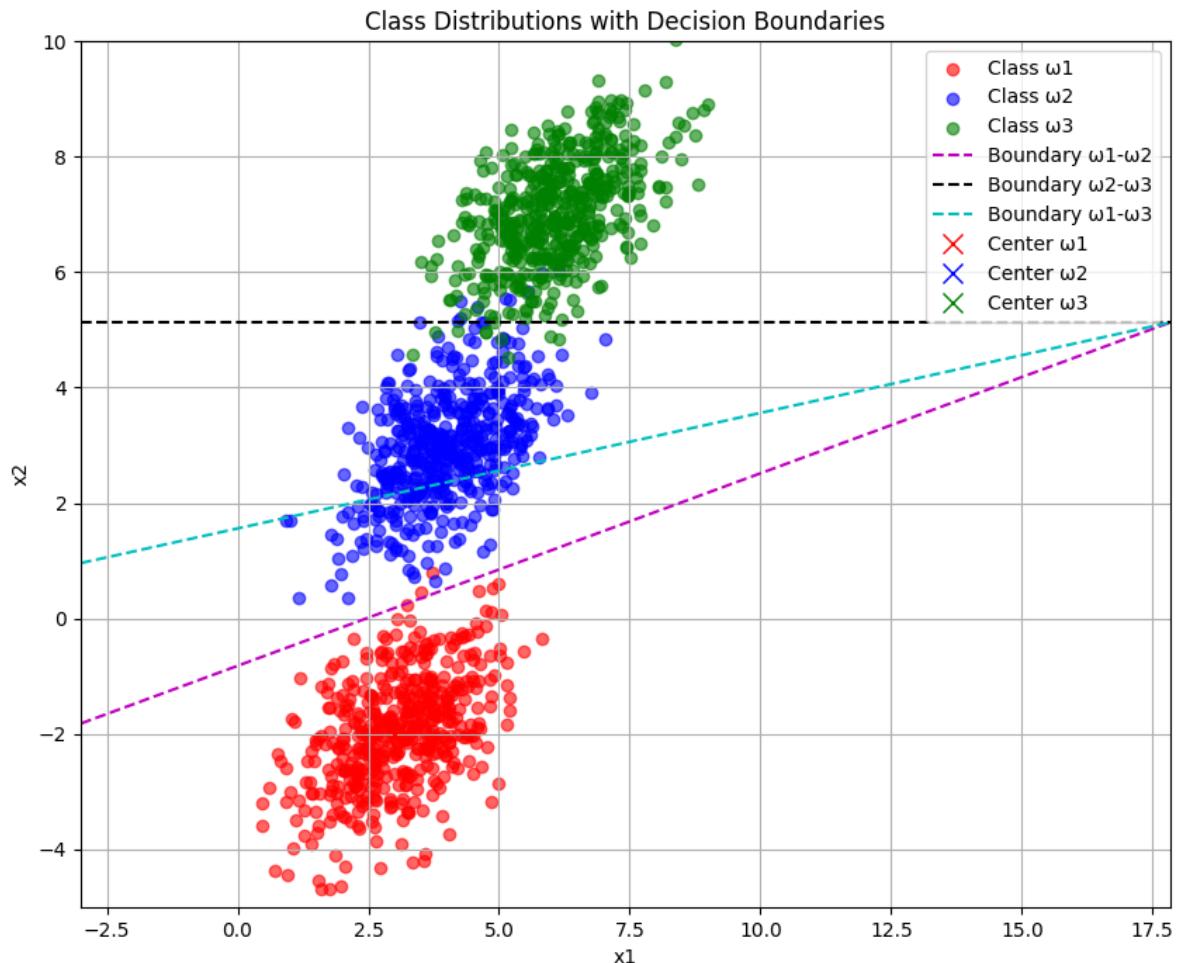


```

import numpy as np
import matplotlib.pyplot as plt
x_vals = np.linspace(0, 30, 1000)
# Boundary line between w1 and w2: 3x1 - 9x2 = 7.3744
boundary12_y = (3 * x_vals - 7.3744) / 9
# Boundary line between w2 and w3: x2 = 5.1277 (horizontal line)
boundary23_y = np.full_like(x_vals, 5.1277)
# Boundary line between w1 and w3: -3x1 + 15x2 = 23.3918
boundary13_y = (3 * x_vals + 23.3918) / 15
# Plotting
plt.figure(figsize=(10, 8))
# Plot decision boundaries
plt.plot(x_vals, boundary12_y, 'r', label='Boundary w1-w2')
plt.plot(x_vals, boundary23_y, 'g', label='Boundary w2-w3')
plt.plot(x_vals, boundary13_y, 'b', label='Boundary w1-w3')
# Additional plot settings
plt.xlabel('x1')
plt.ylabel('x2')
plt.title('Class Distributions with Decision Boundaries')
plt.legend()
plt.grid(True)
plt.xlim(0, 30)
plt.ylim(-5, 10)
# Plotting
plt.figure(figsize=(10, 8))
# Plot decision boundaries
plt.plot(x_vals, boundary12_y, 'm', label='Boundary w1-w2')
plt.plot(x_vals, boundary23_y, 'k', label='Boundary w2-w3')
plt.plot(x_vals, boundary13_y, 'c', label='Boundary w1-w3')
# # Fill areas based on classification regions
plt.fill_between(x_vals, boundary23_y, 10, color='lightcoral', alpha=0.3,
label='Class w3')
plt.fill_between(x_vals, boundary12_y, boundary23_y, where=(boundary12_y
<= boundary23_y),color='lightblue', alpha=0.3, label='Class w2')
plt.fill_between(x_vals, -10, boundary12_y, color='lightgreen', alpha=0.3,
label='Class w1'
# Additional plot settings
plt.xlabel('x1')
plt.ylabel('x2')
plt.title('Class Distributions with Decision Boundaries')
plt.legend()
plt.grid(True)
plt.xlim(0, 17.84126)
plt.ylim(-5, 10)
plt.show()

```

(δ) Δίνεται το ζητούμενο σχήμα:



Για το ζητούμενο σχήμα χρησιμοποιήθηκε ο εξής κώδικας:

```
import numpy as np
import matplotlib.pyplot as plt

# Define parameters for each class
mean1 = np.array([3, -2])
mean2 = np.array([4, 3])
mean3 = np.array([6, 7])
cov_matrix = np.array([[1, 0.5], [0.5, 1]]) # Shared covariance matrix
priors = np.array([0.2, 0.5, 0.3])
```

```

# Generate 500 points for each class
np.random.seed(0) # For reproducibility
p_x_given_w1 = np.random.multivariate_normal(mean1, cov_matrix, 500)
p_x_given_w2 = np.random.multivariate_normal(mean2, cov_matrix, 500)
p_x_given_w3 = np.random.multivariate_normal(mean3, cov_matrix, 500)

# Define decision boundaries as lines based on given equations
x_vals = np.linspace(-3, 20, 1000)
# Boundary line between w1 and w2: 3x1 - 9x2 = 7.3744
boundary12_y = (3 * x_vals - 7.3744) / 9
# Boundary line between w2 and w3: x2 = 5.1277 (horizontal line)
boundary23_y = np.full_like(x_vals, 5.1277)
# Boundary line between w1 and w3: -3x1 + 15x2 = 23.3918
boundary13_y = (3 * x_vals + 23.3918) / 15

# Plotting
plt.figure(figsize=(10, 8))
# Scatter plot for each class
plt.scatter(p_x_given_w1[:, 0], p_x_given_w1[:, 1], color='red',
            label='Class w1', alpha=0.6)
plt.scatter(p_x_given_w2[:, 0], p_x_given_w2[:, 1], color='blue',
            label='Class w2', alpha=0.6)
plt.scatter(p_x_given_w3[:, 0], p_x_given_w3[:, 1], color='green',
            label='Class w3', alpha=0.6)

# Plot decision boundaries
plt.plot(x_vals, boundary12_y, 'm--', label='Boundary w1-w2')
plt.plot(x_vals, boundary23_y, 'k--', label='Boundary w2-w3')
plt.plot(x_vals, boundary13_y, 'c--', label='Boundary w1-w3')
# Plot centers of each class
plt.plot(mean1[0], mean1[1], 'ro', marker='x', markersize=10,
         label='Center w1')
plt.plot(mean2[0], mean2[1], 'bo', marker='x', markersize=10,
         label='Center w2')
plt.plot(mean3[0], mean3[1], 'go', marker='x', markersize=10,
         label='Center w3')

# Additional plot settings
plt.xlabel('x1')
plt.ylabel('x2')
plt.title('Class Distributions with Decision Boundaries')
plt.legend()
plt.grid(True)
plt.xlim(-3, 17.84126)
plt.ylim(-5, 10)
plt.show()

```

(ε) Υπολογίστηκε με δύο τρόπους. Αρχικά, πήρα 10000 δείγματα από την κατανομή $x | \omega_2 \sim N(\mu_2, \Sigma)$ και βλέπουμε το ποσοστό που αυτά σύμφωνα με τον ταξινομιτή Bayes γίνονται misclassified.

Αποτέλεσμα: Probability of misclassification of Class w2 is: 0.0191

Κώδικας:

```
import numpy as np
from scipy.stats import multivariate_normal
# Data
mu1 = np.array([3, -2])
mu2 = np.array([4, 3])
mu3 = np.array([6, 7])
sigma = np.array([[1, 0.5], [0.5, 1]])
priors = [0.2, 0.5, 0.3]

# Creating 10000 samples
num_samples = 10000
samples = multivariate_normal.rvs(mean=mu2, cov=sigma, size=num_samples)

# Misclassification initialization
misclassified_count = 0

# Compute posterior probability and classify them with Bayes
for x in samples:
    # Computation of PDF for every distribution
    p_x_given_w1 = multivariate_normal.pdf(x, mean=mu1, cov=sigma) *
    priors[0]
    p_x_given_w2 = multivariate_normal.pdf(x, mean=mu2, cov=sigma) *
    priors[1]
    p_x_given_w3 = multivariate_normal.pdf(x, mean=mu3, cov=sigma) *
    priors[2]

    # Classification with Bayes classifier
    predicted_class = np.argmax([p_x_given_w1, p_x_given_w2,
    p_x_given_w3])

    # If misclassification then increase variable
    if predicted_class != 1:
        misclassified_count += 1
# Final Output
error_probability = misclassified_count / num_samples
print("Probability of misclassification of Class w2 is:",
error_probability)
```

Ο δεύτερος τρόπος είναι ο υπολογισμός του ολοκληρώματος $p(x | \omega_2)$ στις περιοχές που δεν ανήκει στην κλάση ω_2 .

Αποτέλεσμα: Probability of Misclassification is: 0.01909033805483369

Κώδικας:

```
import numpy as np

from scipy.stats import multivariate_normal
from scipy.integrate import dblquad
# Given parameters
mean_w2 = [4, 3]
cov_matrix = [[1, 0.5], [0.5, 1]]
# Define the distribution for p(x|w2)
rv_w2 = multivariate_normal(mean=mean_w2, cov=cov_matrix)

# Define the boundaries
boundary12 = lambda x1: (3 * x1 - 7.3744) / 9 # Boundary w1-w2
boundary23 = 5.1277 # Boundary w2-w3

# Misclassification region for w3 (x2 > boundary23)
def integrand_w3(x2, x1):
    return rv_w2.pdf([x1, x2])

# Misclassification region for w1 (x2 < boundary12)
def integrand_w1(x2, x1):
    return rv_w2.pdf([x1, x2])

# Integration limits
x1_min, x1_max = -np.inf, 17.84126
# Compute the probability for w3 region
P_error_w3, _ = dblquad(
    integrand_w3,
    x1_min, x1_max,
    lambda x1: boundary23, # Lower bound for x2
    lambda x1: np.inf # Upper bound for x2
)
# Compute the probability for w1 region
P_error_w1, _ = dblquad(
    integrand_w1,
    x1_min, x1_max,
    lambda x1: -np.inf, # Lower bound for x2
    lambda x1: boundary12(x1) # Upper bound for x2
)
# Total misclassification probability
P_misclassification = P_error_w1 + P_error_w3
print(f"Probability of Misclassification is: {P_misclassification}")
```

Άσκηση 1.4

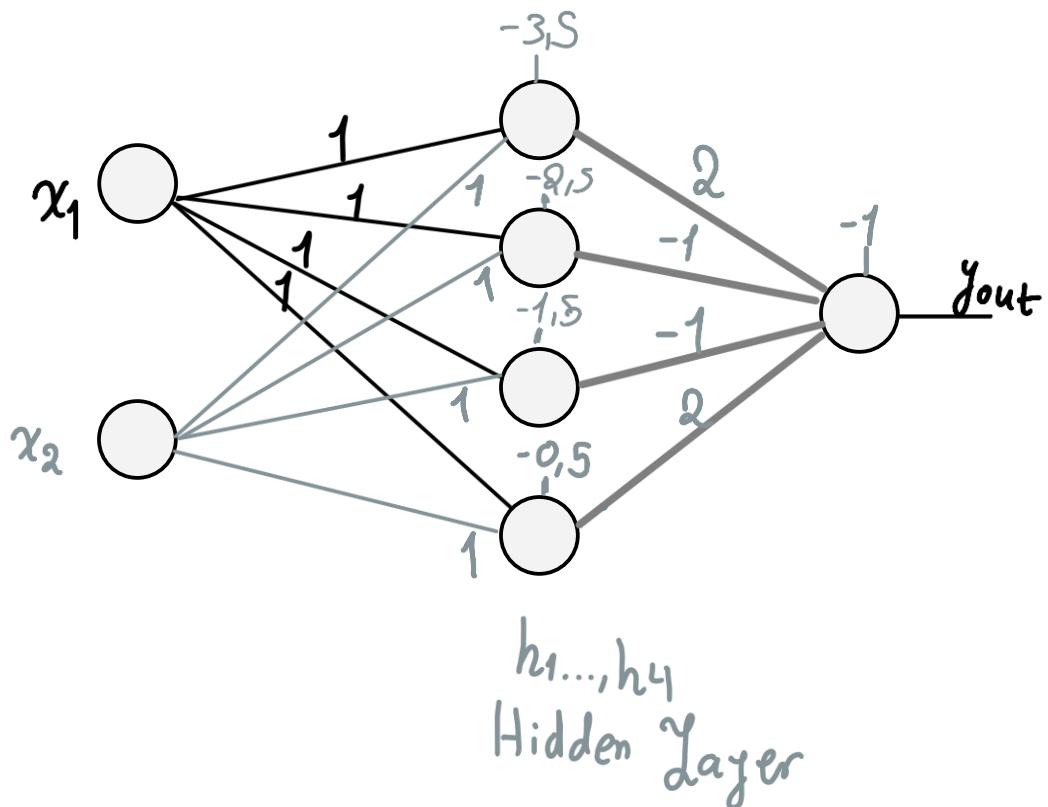
Ερώτημα A

Πίνακας Input – Output.

x_1	x_2	$y = x_1 + x_2 \text{ mod } 3$
0	0	0
0	1	1
0	2	2
1	0	1
1	1	2
1	2	0
2	0	2
2	1	0
2	2	1

Ορίζουμε ως συνάρτηση ενεργοποίησης την ακόλουθη:

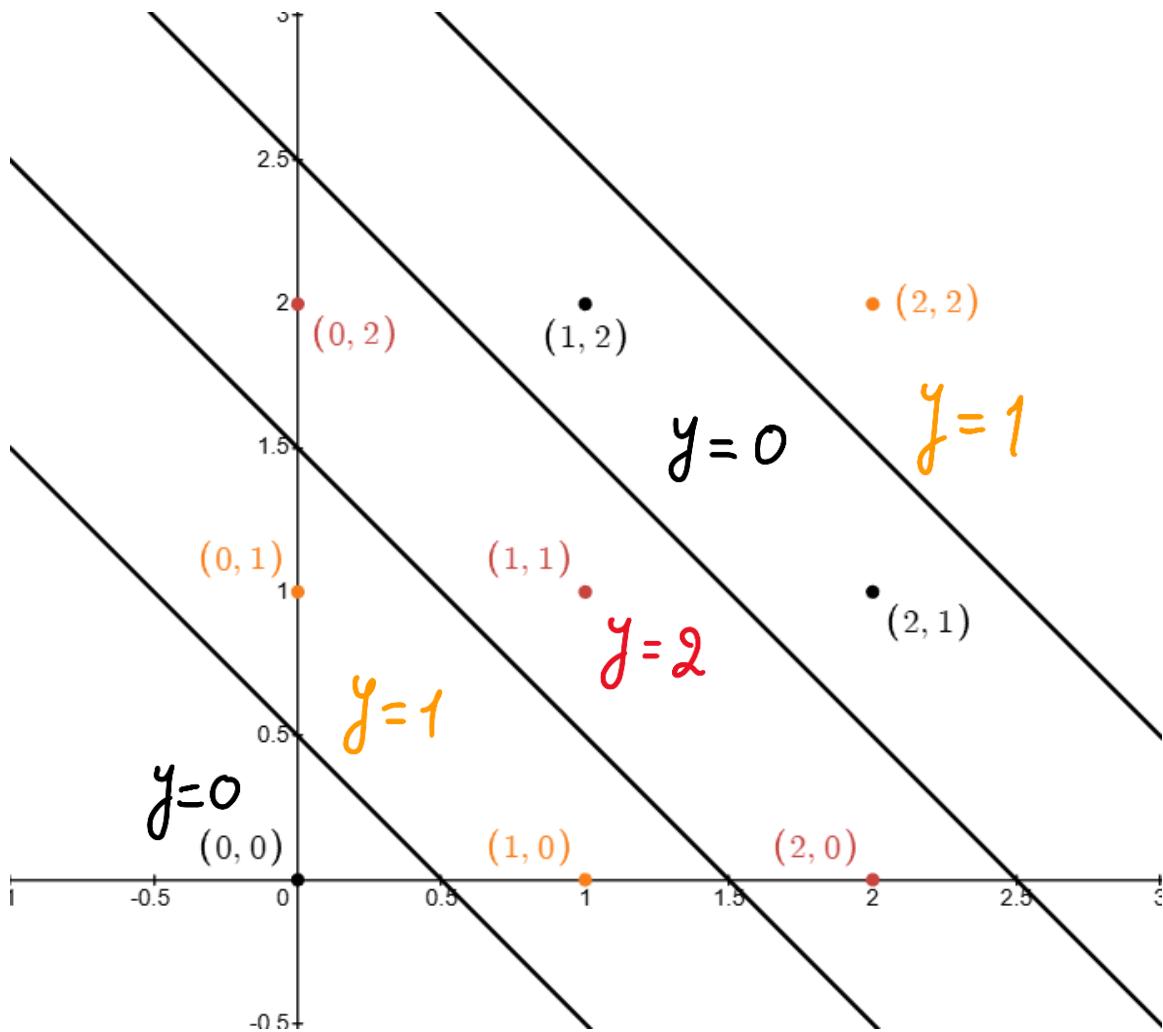
$$f(x) = \begin{cases} 0, & x < 0 \\ 1, & x > 0 \\ 2, & x = 0 \end{cases}$$



Άρα, έχουμε αναλυτικά:

- $w_{i,j} = 1 \forall i, j$ και $b_{h_1} = -3.5, b_{h_2} = -2.5, b_{h_3} = -1.5, b_{h_4} = -0.5$
- $a_1 = 2, a_2 = -1, a_3 = -1, a_4 = 2$

Ερώτημα B



Ερώτημα Γ

Κατασκευάζουμε τους ακόλουθους πίνακες για να ελέγξουμε όλες τις τιμές των x_1, x_2

x_1	x_2	h_1	$f(h_1)$	h_2	$f(h_2)$	h_3	$f(h_3)$	h_4	$f(h_4)$
0	0	-3.5	0	-2.5	0	-1.5	0	-0.5	0
0	1	-2.5	0	-1.5	0	-0.5	0	0.5	1
0	2	-1.5	0	-0.5	0	0.5	1	1.5	1
1	0	-2.5	0	-1.5	0	-0.5	0	0.5	1
1	1	-1.5	0	-0.5	0	0.5	1	1.5	1
1	2	-0.5	0	0.5	1	1.5	1	2.5	1
2	0	-1.5	0	-0.5	0	0.5	1	1.5	1
2	1	-0.5	0	0.5	1	1.5	1	2.5	1
2	2	0.5	1	1.5	1	2.5	1	3.5	1

$f(h_1)$	$f(h_2)$	$f(h_3)$	$f(h_4)$	$y_{out} = 2f(h_1) - f(h_2) - f(h_3) + 2f(h_4) - 1$	$f(y_{out})$
0	0	0	0	-1	0
0	0	0	1	1	1
0	0	1	1	0	2
0	0	0	1	1	1
0	0	1	1	0	2
0	1	1	1	-1	0
0	0	1	1	0	2
0	1	1	1	-1	0
1	1	1	1	1	1

Συγκρίνουμε και παρατηρούμε πως το δίκτυο μας υπολογίζει σωστά τις εξόδους για κάθε δυνατό συνδυασμό εισόδων.

$f(y_{out})$	$y = x_1 + x_2 \bmod 3$
0	0
1	1
2	2
1	1
2	2
0	0
2	2
0	0
1	1

Aorunon 1.5

(a)

a.1: Οι λουρές να δείχνουν τις $K(x_i, x_j) = K(x_j, x_i)$

Από το οριόμενο $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$, όταν ευνόησετε πικάκια στον χώρο Q

Το ευνόησετε πικάκια, όπου υπόθετα γίνονται δράστες, έχει την ιδιότητα της συμμετρίας. Απλωτά, αν u, v διανομές στον Q τότε: $\langle u, v \rangle = \langle v, u \rangle$

Άρα $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \langle \phi(x_j), \phi(x_i) \rangle = K(x_j, x_i) = K(x_i, x_j)$

a.2: Εξαγετε $K(x_i, x_j) = \exp\left(-\frac{1}{2} \|x_i - x_j\|^2\right) = \langle \phi(x_i), \phi(x_j) \rangle @$

$$\rightarrow \| \phi(x_i) - \phi(x_j) \|^2 = \langle \phi(x_i) - \phi(x_j), \phi(x_i) - \phi(x_j) \rangle \stackrel{\text{Ιδιότητας}}{=} \underbrace{\exp(-\frac{1}{2} \|x_i - x_j\|^2)}_{\text{Εσ. Γινομένων}}$$

$$= \langle \phi(x_i), \phi(x_i) \rangle - 2 \langle \phi(x_i), \phi(x_j) \rangle + \langle \phi(x_j), \phi(x_j) \rangle \quad (1)$$

$$\text{Άρα } \langle \phi(x_i), \phi(x_i) \rangle @ \exp\left(-\frac{1}{2} \|x_i - x_i\|^2\right) = \exp(0) = 1$$

$$\langle \phi(x_i), \phi(x_j) \rangle @ \exp\left(-\frac{1}{2} \|x_i - x_j\|^2\right) = \exp(0) = 1$$

Άρα $(1) \Rightarrow \| \phi(x_i) - \phi(x_j) \|^2 = 1 - 2 \langle \phi(x_i), \phi(x_j) \rangle = 1 - 2K(x_i, x_j) \quad (1')$

Όμως $K(x_i, x_i) = \langle \phi(x_i), \phi(x_i) \rangle = \exp\left(-\frac{1}{2} \|x_i - x_i\|^2\right) > 0 \rightarrow \in [0, 1]$

Άρα $K(x_i, x_i) > 0 \Leftrightarrow -2K(x_i, x_j) < 0 \Leftrightarrow 2 - 2K(x_i, x_j) < 2 \stackrel{(1')}{\Rightarrow} \underline{\| \phi(x_i) - \phi(x_j) \|^2} < 2$

Δεν αυταια τις πιστώνται τις μεταξύ x_i, x_j εγκέπονται στην άποψη των λουρών:

Άρα $\underline{\| \phi(x_i) - \phi(x_j) \|^2} \leq 2$

(B) Ar δεωριούσης για τις δύο μεμβράνες μεταξύ x_i έχουμε τις $\|x_{far} - x_i\|^2$,

$$\Rightarrow -\frac{1}{2} \|x_{far} - x_i\|^2 \ll 0 \Leftrightarrow \exp\left(-\frac{1}{2} \|x_{far} - x_i\|^2\right) \approx 1$$

$$\Rightarrow 0 < K(x_{far}, x_i) \ll 1 \rightarrow K(x_i, x_{far}) \approx 0$$

Άρα $f(x_{far}; a, \hat{w}_o) = \sum_{i \in SV} a_i y_i \cdot \alpha_i K(x_i, x_{far}) + \hat{w}_o$

$$\Rightarrow f(x_{far}; a, \hat{w}_o) \approx \hat{w}_o$$