

2η Δερπά Ακριούσιων Μηχανών 03121089 Πανεπιστήμιος Πλούτος

Άσκηση 2.1

Root | Non-Root

$$a) \text{Gini}(\text{Root}) = 1 - \sum_{i \in \text{labels}(D)} p_i^2 = 1 - \left(\frac{5}{9}\right)^2 - \left(\frac{4}{9}\right)^2 = 1 - \frac{25}{81} - \frac{16}{81} = \frac{81-41}{81} = \frac{40}{81}$$

$$\Rightarrow \text{Gini}(\text{Root}) \approx 0.4938 \quad ①$$

$$b) \text{Gini}(X_1) = \sum_{v \in \text{values}(X_1)} \frac{|\{x_i \mid X_1=v\}|}{|\text{Root}|} \cdot \text{gini}(X_1=v) = \frac{|\{x_i \mid X_1=0\}|}{|\text{Root}|} \cdot \text{gini}(X_1=0) + \frac{|\{x_i \mid X_1=1\}|}{|\text{Root}|} \cdot \text{gini}(X_1=1)$$

$$\Rightarrow \text{Gini}(X_1) = \frac{4}{9} \cdot \text{gini}(X_1=0) + \frac{5}{9} \cdot \text{gini}(X_1=1) \quad ②$$

$$\blacksquare \text{gini}(X_1=0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5 \quad 2.a$$

$$\blacksquare \text{gini}(X_1=1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48 \quad 2.b$$

$$② \xrightarrow[2.b]{2.a} \boxed{\text{Gini}(X_1) = 0.488} \quad ③$$

$$c) \text{Gini}(X_2) = \frac{4}{9} \text{gini}(X_2=0) + \frac{5}{9} \text{gini}(X_2=1) \quad ④$$

$$\blacksquare \text{gini}(X_2=0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5 \quad 3.a$$

$$\blacksquare \text{gini}(X_2=1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48 \quad 3.b$$

$$④ \xrightarrow[3.b]{3.a} \boxed{\text{Gini}(X_2) = 0.488} \quad ⑤$$

$$d) \text{Gini}(X_3) = \frac{5}{9} \text{gini}(X_3=0) + \frac{4}{9} \text{gini}(X_3=1) \quad ⑥$$

$$\blacksquare \text{gini}(X_3=0) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48 \quad 4.a$$

$$\blacksquare \text{gini}(X_3=1) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5 \quad 4.b$$

$$⑥ \xrightarrow[4.b]{4.a} \text{Gini}(X_3) = 0.491$$

$$e) \text{Gini}(X_4) = \frac{3}{9} \text{gini}(X_4=0) + \frac{6}{9} \text{gini}(X_4=1) \quad ⑦$$

$$\blacksquare \text{gini}(X_4=0) = 1 - \left(\frac{3}{3}\right)^2 - \left(\frac{0}{3}\right)^2 = 0 \quad 5.a$$

$$\blacksquare \text{gini}(X_4=1) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 = 0.444 \quad 5.b$$


$$⑦ \Rightarrow \boxed{\text{Gini}(X_4) = 0.296} \quad ⑧$$

Apa Information gain na  $X_1, X_2, X_3, X_4$  given:

- $ig(X_1) = \text{gini}(\text{Root}) - \text{gini}(X_1) = 0.0058$
- $ig(X_2) = \text{gini}(\text{Root}) - \text{gini}(X_2) = 0.0058$
- $ig(X_3) = \text{gini}(\text{Root}) - \text{gini}(X_3) = 0.0498$
- $ig(X_4) = \text{gini}(\text{Root}) - \text{gini}(X_4) = 0.1972$

Apa με την αρχική διαίρεση των  $X_4$  αντικαθίστανται την προσέξερη πληροφορία:

Δέντρο Ανάπτυξης:



Για  $X_4=1$ :

$$\bullet \text{Gini}(\text{Root}) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 = 1 - \frac{1}{9} - \frac{4}{9} = \frac{9-5}{9} = \frac{4}{9} \Rightarrow \text{Gini}(\text{Root}) \approx 0.444 \quad (1)$$

$$\bullet \text{Gini}(X_1) = \frac{|X_1=0|}{|\text{Root}|} \cdot \text{gini}(X_1=0) + \frac{|X_1=1|}{|\text{Root}|} \cdot \text{gini}(X_1=1) = \frac{3}{6} \text{gini}(X_1=0) + \frac{3}{6} \text{gini}(X_1=1) \quad (2)$$

$$\blacksquare \text{gini}(X_1=0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 \approx 0.444 \quad (2.a)$$

$$\blacksquare \text{gini}(X_1=1) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 \approx 0.444 \quad (2.b)$$

$$(2) \xrightarrow[2.b]{2.a} \text{Gini}(X_1) = 0.444 = \text{Gini}(\text{Root}) \text{ apa } ig(X_1) = 0$$

$$\bullet \text{Gini}(X_2) = \frac{2}{6} \text{gini}(X_2=0) + \frac{4}{6} \text{gini}(X_2=1) \quad (3)$$

$$\blacksquare \text{gini}(X_2=0) = 1 - \left(\frac{2}{2}\right)^2 + \left(\frac{0}{2}\right)^2 = 0 \quad 3.a'$$

$$\blacksquare \text{gini}(X_2=1) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0.5 \quad 3.b'$$


$$(3) \xrightarrow[3.b]{3.a'} \text{gini}(X_2) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0.5 = \frac{1}{3} = 0.3333 \text{ apa } ig(X_2) = 0.444 - 0.3333 = \boxed{ig(X_2) = 0.111}$$

$$\bullet \text{gini}(X_3) = \frac{3}{6} \text{gini}(X_3=0) + \frac{3}{6} \text{gini}(X_3=1) \quad (4)$$

$$\blacksquare \text{gini}(X_3=0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0.444 \quad \} (4) \Rightarrow \text{gini}(X_3) = 0.444 = \text{gini}(\text{Root})$$

$$\blacksquare \text{gini}(X_3=1) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0.444 \quad \text{Apa } \boxed{ig(X_3) = 0}$$

Αριθμός δέντρων αποφάσεων:



Gini index σημ.  $Y_4=1$  και  $Y_2=1$

$$\text{gini}(\text{Root}) = 1 - \left(\frac{2}{4}\right)^2 + \left(\frac{2}{4}\right)^2 = 0,5$$

- $\text{gini}(X_1) = \frac{2}{4} \text{gini}(X_1=0) + \frac{2}{4} \text{gini}(X_1=1)$

- $\text{gini}(X_1=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5 \quad \left\{ \text{gini}(X_1)=0,5 \Rightarrow ig(X_1)=0\right.$

- $\text{gini}(X_1=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$


- $\text{gini}(X_3) = \frac{2}{4} \text{gini}(X_3=0) + \frac{2}{4} \text{gini}(X_3=1)$

- $\text{gini}(X_3=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5 \quad \left\{ \text{gini}(X_3)=0,5 \Rightarrow ig(X_3)=0\right.$

- $\text{gini}(X_3=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$


Διαλέγουμε το  $X_1$  (Αριθμός πρώτων αρμόδιων για την απόφαση)

Τελικός δέντρο αποφάσεων



B) Παρατηρούμε ότι αν  $X_3 \text{(xor)} X_1 = 0$  τότε  $Y = -1$  ενώ αν  $X_1 \text{(xor)} X_3 = 1$ ,  $Y = 1$

Αριθμός εξιτηνίων από το  $X_3$ :



8) Για το πρώτο υπωρίωδο:

Γενική παρατεταμένη τις ίσο μηδέσερο το  $\text{gini}(X_i)$  και ως μεταβάσερο το  $ig(X_i)$

$$\text{Άριθμος gini}(X_1) = \frac{2}{3} \text{gini}(X_1=0) + \frac{1}{3} \text{gini}(X_1=1)$$

$$\text{ΗΕ } \text{gini}(X_1=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5 \quad \left\{ \text{gini}(X_1) = \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{3} = 0,333 \Rightarrow \boxed{\text{gini}(X_1) = 0,33} \right.$$

$$\text{gini}(X_1=1) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0 \quad \left. \right\}$$

$$\circ \text{gini}(X_2) = \text{gini}(X_2=1) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 1 - \frac{4}{9} - \frac{1}{9} = \frac{4}{9} = \boxed{0,444 = \text{gini}(k)}$$


$$\circ \text{gini}(X_3) = \frac{2}{3} \text{gini}(X_3=0) + \frac{1}{3} \text{gini}(X_3=1)$$

$$\text{ΗΕ } \text{gini}(X_3=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5 \quad \left\{ \boxed{\text{gini}(X_3) = 0,333} \right.$$

$$\text{gini}(X_3=1) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0 \quad \left. \right\}$$

$$\circ \text{gini}(X_4) = \frac{1}{3} \text{gini}(X_4=0) + \frac{2}{3} \text{gini}(X_4=1) = 0,333 \quad (\text{iδια λογική με τη προηγουμένη})$$

Επιλεγμένη αρχεύτικη του  $X_1$ :




Τιμή  $X_1=0$ : (Κατευθείαν το  $X_3$  παρατηρήθηκε τις διαχωριστικές κλίσεις)

$$\text{gini}(X_2) = \text{gini}(X_2=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$\text{gini}(X_3) = \frac{1}{2} \text{gini}(X_3=0) + \frac{1}{2} \text{gini}(X_3=1) = 0$$

$$\text{gini}(X_4) = \text{gini}(X_4=1) = \frac{1}{2} - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

Άριθμος του πρώτου υπωρίωδο



Δευτέρου γύρου δομή:


$$\text{gini}(X_1) = \text{gini}(X_1=0) + \text{gini}(X_1=1) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0.444$$

$$\text{gini}(X_2) = \frac{1}{3} \text{gini}(X_2=0) + \frac{2}{3} \text{gini}(X_2=1) = \frac{2}{3} \left(1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2\right) = 0.333$$

$$\text{gini}(X_3) = \frac{2}{3} \text{gini}(X_3=0) + \frac{1}{3} \text{gini}(X_3=1) = \frac{2}{3} \left(1 - \left(\frac{2}{2}\right)^2 - \left(\frac{0}{2}\right)^2\right) = 0$$

$$\text{gini}(X_4) = 0.333 \text{ (ιδη λόγω με } \text{gini}(X_2))$$


Άρη η δεύτερη γύρου δομή:



Τρίτο γύρου δομή:

$$\text{gini}(X_4) = 0 \text{ (Αρη η } X_4=0 \rightarrow Y=1 \text{ και } X_4=1 \rightarrow Y=-1)$$

Ζερκελέζερες ήδη οι αύτα δικτύες δε σίνα περιδιπέρα των μηδενών, είπα



Άσκηση 2.2

- a)  $X = \{(x_1, y_1), \dots, (x_8, y_8)\}$   $x_i, y_i$  αριθμοί των με τα μήκη στην συμμόρφωση  $(y_{i+1})$  των διστάνσεων ανάτομων  $(x_i, y_i)$  με τα δύο κέντρα και αναδέιπνε αντίστοιχο σημείο στην κάτιον με την μηδενική ανάτομη. Κέντρα:  $C_1 = (3, 3)$ ,  $C_2 = (4, 4)$

Ανθελμη γεωδεσικής απόστασης:  $d((x_i, y_i), C_j) = \sqrt{(x_i - C_{j,x})^2 + (y_i - C_{j,y})^2}$

Εγραψε Python script για αυτό.

## Ασκηση 2.2

### Ερώτημα A

```
● PS G:\My Drive\Ece Ntua\7th Semester\Machine Learning\Series of Exercises\Exercise 2> python3 .\Exercise_2a.py

    === Iteration 0 ===
Point: (2, 3), Distances: [1.0, 2.23606797749979], Assigned to Cluster: 1
Point: (3, 2), Distances: [1.0, 2.23606797749979], Assigned to Cluster: 1
Point: (1, 2), Distances: [2.23606797749979, 3.605551275463989], Assigned to Cluster: 1
Point: (4, 5), Distances: [2.23606797749979, 1.0], Assigned to Cluster: 2
Point: (5, 4), Distances: [2.23606797749979, 1.0], Assigned to Cluster: 2
Point: (3, 4), Distances: [1.0, 1.0], Assigned to Cluster: 1
Point: (6, 4), Distances: [3.1622776601683795, 2.0], Assigned to Cluster: 2
Point: (6, 5), Distances: [3.605551275463989, 2.23606797749979], Assigned to Cluster: 2
New Centroids: [[2.25 2.75]
[5.25 4.5 ]]

    === Iteration 1 ===
Point: (2, 3), Distances: [0.3535533905932738, 3.5794552658190883], Assigned to Cluster: 1
Point: (3, 2), Distances: [1.0606601717798212, 3.3634060117684275], Assigned to Cluster: 1
Point: (1, 2), Distances: [1.4577379737113252, 4.930770730829005], Assigned to Cluster: 1
Point: (4, 5), Distances: [2.850438562747845, 1.346291201783626], Assigned to Cluster: 2
Point: (5, 4), Distances: [3.020761493398643, 0.5590169943749475], Assigned to Cluster: 2
Point: (3, 4), Distances: [1.4577379737113252, 2.3048861143232218], Assigned to Cluster: 1
Point: (6, 4), Distances: [3.952847075210474, 0.9013878188659973], Assigned to Cluster: 2
Point: (6, 5), Distances: [4.373213921133975, 0.9013878188659973], Assigned to Cluster: 2
New Centroids: [[2.25 2.75]
[5.25 4.5 ]]

Convergence reached.

    === Final Output ===
Final Centroids:
Cluster 1: [2.25 2.75]
Cluster 2: [5.25 4.5 ]

Final Cluster Assignments:
Point 1: Assigned to Cluster 1
Point 2: Assigned to Cluster 1
Point 3: Assigned to Cluster 1
Point 4: Assigned to Cluster 2
Point 5: Assigned to Cluster 2
Point 6: Assigned to Cluster 1
Point 7: Assigned to Cluster 2
Point 8: Assigned to Cluster 2
○ PS G:\My Drive\Ece Ntua\7th Semester\Machine Learning\Series of Exercises\Exercise 2>
```

Βοηθητικός κώδικας που χρησιμοποιήθηκε:

```
import numpy as np
# Data
points = np.array([[2, 3], [3, 2], [1, 2], [4, 5],
                   [5, 4], [3, 4], [6, 4], [6, 5]])

# Initialization of centroids
centroids = np.array([[3, 3], [4, 4]])

def euclidean_distance(point, centroid):
    """Calculation of the Euclidean distance between a point and a
    centroid"""
    return np.sqrt(np.sum((point - centroid) ** 2))
```

```

def assign_points_to_clusters(points, centroids):
    """Assign each point to the nearest centroid"""
    clusters = []
    for point in points:
        distances = [euclidean_distance(point, centroid) for centroid in
centroids]
        cluster = np.argmin(distances) # Returns the index of the nearest
centroid
        clusters.append(cluster)
    return np.array(clusters)

def update_centroids(points, clusters, k):
    """Calculation of new centroids as the mean of the points in each
cluster"""
    new_centroids = []
    for i in range(k):
        cluster_points = points[clusters == i]
        if len(cluster_points) > 0: # If there are points in the cluster
            new_centroid = np.mean(cluster_points, axis=0)
        else: # If there are no points, retain the old centroid
            new_centroid = centroids[i]
        new_centroids.append(new_centroid)
    return np.array(new_centroids)

# Execution of the algorithm
iteration = 0
k = len(centroids)
while True:
    print(f"\n==== Iteration {iteration} ====")
    # Calculation of distances and assignment
    clusters = assign_points_to_clusters(points, centroids)
    for i, point in enumerate(points):
        distances = [euclidean_distance(point, centroid) for centroid in
centroids]
        print(f"Point: ({point[0]}, {point[1]}), Distances: {distances},
Assigned to Cluster: {clusters[i] + 1}")
    # Calculation of new centroids
    new_centroids = update_centroids(points, clusters, k)
    print(f"New Centroids: {new_centroids}")
    # Convergence check
    if np.allclose(centroids, new_centroids):
        print("\nConvergence reached.")
        break
    centroids = new_centroids
    iteration += 1

# Final output
print("\n==== Final Output ====")
print("Final Centroids:")
for i, centroid in enumerate(centroids, 1):
    print(f" Cluster {i}: {centroid}")
print("\nFinal Cluster Assignments:")
for i, cluster in enumerate(clusters, 1):
    print(f" Point {i}: Assigned to Cluster {cluster + 1}")

```

## Ερώτημα Β, Γ

Ακολουθεί τα αποτελέσματα του αλγορίθμου k-means με όλα τα χαρακτηριστικά και με μόνο δύο, καθώς και ο αντίστοιχος βοηθητικός κώδικας που χρησιμοποιήθηκε.

```
PS G:\My Drive\Ece Ntua\7th Semester\Machine Learning\Series of Exercises\Exercise 2> python .\Exercise_2b_c_d.py

Convergence reached!

== (b) Full Feature Set ==
Confusion Matrix:
[[50  0  0]
 [ 0 48  2]
 [ 0 14 36]]

Accuracy (Full Features): 89.33%

Convergence reached!

== (c) Two Features ==
Confusion Matrix:
[[50  0  0]
 [ 0 48  2]
 [ 0  6 44]]

Accuracy: 94.67%

== (d) Comparison ==
Accuracy with Full Features: 89.33%
Accuracy with Two Features: 94.67%
```

```
import pandas as pd
import numpy as np
from sklearn.metrics import confusion_matrix, accuracy_score
import matplotlib.pyplot as plt
from sklearn.preprocessing import LabelEncoder
from collections import Counter

# Load the dataset
data = pd.read_csv('iris.csv')
data = data.drop(columns=['Id'])

# Encode Species to numerical values for comparison
label = LabelEncoder()
data['SpeciesEncoded'] = label.fit_transform(data['Species'])

# K-means algorithm implementation
def k_means(X, k, epsilon=1e-5, max_iterations=100):
    # Random initialization of centroids
    np.random.seed(42)
    centroids = X[np.random.choice(X.shape[0], k, replace=False)]

    for iteration in range(max_iterations):
        # Assign points to the nearest centroid
        distances = np.linalg.norm(X[:, np.newaxis] - centroids, axis=2)
```

```

clusters = np.argmin(distances, axis=1)

# Update centroids
new_centroids = np.array(
    [X[clusters == i].mean(axis=0) for i in range(k)])

# Convergence criterion
if np.linalg.norm(new_centroids - centroids) < epsilon:
    print("\nConvergence reached!")
    break

centroids = new_centroids

return clusters, centroids

# Function to remap clusters to match true labels
def remap_clusters(true_labels, clusters):
    # Create a mapping from clusters to true labels based on majority vote
    mapping = {}
    for cluster_id in np.unique(clusters):
        # Find true labels corresponding to points in this cluster
        true_labels_in_cluster = true_labels[clusters == cluster_id]

        # Get the most common true label for this cluster
        most_common_label = Counter(
            true_labels_in_cluster).most_common(1)[0][0]
        mapping[cluster_id] = most_common_label

    # Remap the clusters
    remapped_clusters = np.array([mapping[cluster] for cluster in clusters])
    return remapped_clusters

# (b) Apply k-means with all features
X_full = data[['SepalLengthCm', 'SepalWidthCm',
                'PetalLengthCm', 'PetalWidthCm']].values
clusters_full, centroids_full = k_means(X_full, k=3)

# Map cluster labels to the true labels for comparison
true_labels = data['SpeciesEncoded'].values
clusters_full = remap_clusters(true_labels, clusters_full)
conf_matrix_full = confusion_matrix(true_labels, clusters_full)
accuracy_full = accuracy_score(true_labels, clusters_full)

```

```

print("\n==== (b) Full Feature Set ===")
print("Confusion Matrix:")
print(conf_matrix_full)
print(f"\nAccuracy (Full Features): {accuracy_full * 100:.2f}%")


# (c) Apply k-means with only two features
X_two = data[['PetalLengthCm', 'PetalWidthCm']].values
clusters_two, centroids_two = k_means(X_two, k=3)
clusters_two = remap_clusters(true_labels, clusters_two)
conf_matrix_two = confusion_matrix(true_labels, clusters_two)
accuracy_two = accuracy_score(true_labels, clusters_two)

print("\n==== (c) Two Features ===")
print("Confusion Matrix:")
print(conf_matrix_two)
print(f"Accuracy: {accuracy_two * 100:.2f}%")
# (d) Compare results
print("\n==== (d) Comparison ===")
print(f"Accuracy with Full Features: {accuracy_full * 100:.2f}%")
print(f"Accuracy with Two Features: {accuracy_two * 100:.2f}%")

# Plotting for (c)
plt.figure(figsize=(8, 6))
for i in range(3):
    cluster_points = X_two[clusters_two == i]
    plt.scatter(cluster_points[:, 0],
                cluster_points[:, 1], label=f'Cluster {i+1}')
plt.scatter(centroids_two[:, 0], centroids_two[:, 1],
            color='black', marker='x', s=100, label='Centroids')
plt.xlabel('Petal Length (cm)')
plt.ylabel('Petal Width (cm)')
plt.title('(c) K-means Clustering on Two Features')
plt.legend()
plt.show()

```

Επίσης, ακολουθεί γραφική απεικόνιση του ζητούμενου.



#### Ερώτημα Δ

Χρησιμοποιώντας και τα 4 χαρακτηριστικά, το success rate ήταν 89.33%, ενώ με μόνο το μήκος και το πλάτος των πετάλων αυξήθηκε στο 94.67%. Αυτό δείχνει ότι τα χαρακτηριστικά των πετάλων είναι πιο διακριτικά για τις κλάσεις, ενώ η προσθήκη των χαρακτηριστικών των σεπάλων εισάγει θόρυβο και μειώνει την ακρίβεια.

Συνεπώς, η χρήση όλων των χαρακτηριστικών δεν οδηγεί πάντα σε καλύτερα αποτελέσματα, καθώς μπορεί να περιλαμβάνει περιττή ή παραπλανητική πληροφορία που επηρεάζει αρνητικά την ταξινόμηση.

## Axiom 2.3

- $\exists d_0 \in \mathbb{R}: -\infty < d_0 \leq d(x,y) < \infty, \forall x, y \in X$

a) Για μέρο αναφορικας πρέπει: •  $d(x,x) = d_0, \forall x \in X$

$$d: \boxed{X \times X} \rightarrow \mathbb{R}$$

- $d(x,y) = d(y,x), \forall x, y \in X$

Έποικτε  $d_c(x,y) = 1 - \cos \delta_{xy}$  και  $\cos \delta_{xy} = \frac{x \cdot y}{\|x\| \cdot \|y\|}$  (Από γραμμική Αλγεβρα)

$$\bullet -1 \leq \cos \delta_{xy} \leq 1 \Rightarrow -1 \leq -\cos \delta_{xy} \leq 1 \Rightarrow \boxed{0 \leq 1 - \cos \delta_{xy}}$$

$$\bullet d_c(x,x) = 1 - \cos \delta_{xx} = 1 - \frac{x \cdot x}{\|x\| \cdot \|x\|} = 1 - \frac{\|x\|^2}{\|x\| \cdot \|x\|} = 0 \Rightarrow \boxed{d_c(x,x) = 0}$$

$$\bullet d_c(x,y) = 1 - \cos \delta_{xy} = 1 - \frac{x \cdot y}{\|x\| \cdot \|y\|} \quad \begin{matrix} \text{ιδίως} \\ \text{εσ. μη διανομέας} \end{matrix} \quad 1 - \frac{y \cdot x}{\|y\| \cdot \|x\|} = 1 - \cos \delta_{yx} = d_c(y,x)$$

$$\Rightarrow \boxed{d_c(x,y) = d_c(y,x)}$$

Από τη παρατήρηση στη  $d_c(x,y)$  είναι μέρο αναφορικας.

Τια να είναι μέρος αναφορικας, πρέπει:  $d_c(x,y) = 0$  αν και μόνο αν  $x=y$

~~αποτελεσματικά διαφορετικός~~ άλλος ότις αν  $y=2x$  τότε  $\Delta$

$$d_c(x,2x) = 1 - \cos \delta_{x,2x} = 1 - \frac{x \cdot 2x}{\|x\| \cdot \|2x\|} = 1 - \frac{2(x \cdot x)}{2 \cdot \|x\| \cdot \|x\|} = 0 \quad \begin{matrix} \text{από στην} \\ \text{μέρος αναφορικας.} \end{matrix}$$

## Ασκηση 2.3

### Ερώτημα B

- Ο πίνακας προτύπων (pattern matrix)  $D(X)$  είναι ο  $N \times l$  η  $i$ -οστή γραμμή του οποίου είναι το (αντεστραμμένο)  $i$ -οστό διάνυσμα του  $X$ .
- Ο πίνακας ομοιότητας (ανομοιότητας),  $P(X)$ , είναι ένας  $N \times N$ , του οποίου το στοιχείο  $(i, j)$  ισούται με το βαθμό ομοιότητας  $s(x_i, x_j)$  (ανομοιότητας  $d(x_i, x_j)$ ) των διανυσμάτων  $x_i$  και  $x_j$ . Ο πίνακας αυτός είναι γνωστός και ως πίνακας εγγύτητας.

```
PS G:\My Drive\Ece Ntua\7th Semester\Machine Learning\Series of Exercises\Exercise 2> python3 .\Exercise_3b_c_d.py

D(X) - Distance Matrix:
[[1 5]
 [3 4]
 [0 2]
 [5 4]
 [2 6]
 [3 3]
 [2 3]
 [4 2]]

P(X) - Proximity Matrix:
      Point 1  Point 2  Point 3  Point 4  Point 5  Point 6  Point 7  Point 8
Point 1  0.000  0.098  0.019  0.234  0.008  0.168  0.075  0.386
Point 2  0.098  0.000  0.200  0.032  0.051  0.010  0.002  0.106
Point 3  0.019  0.200  0.000  0.375  0.051  0.293  0.168  0.553
Point 4  0.234  0.032  0.375  0.000  0.160  0.006  0.047  0.022
Point 5  0.008  0.051  0.051  0.160  0.000  0.186  0.035  0.293
Point 6  0.168  0.010  0.293  0.006  0.106  0.000  0.019  0.051
Point 7  0.075  0.002  0.168  0.047  0.035  0.019  0.000  0.132
Point 8  0.386  0.106  0.553  0.022  0.293  0.051  0.132  0.000
```

Βοηθητικός

κώδικας:

```
import numpy as np

import pandas as pd
import matplotlib.pyplot as plt
from scipy.cluster.hierarchy import linkage, dendrogram
from scipy.spatial.distance import pdist, squareform

# Data
X = np.array([[1,5],[3,4],[0, 2], [5, 4], [2, 6], [3, 3], [2, 3], [4, 2]])

# D(X)
D = X

# Function to compute the proximity matrix using dc(x,y)=1 - cos(theta_xy)
def proximity_matrix(X):
    n = X.shape[0]
    P = np.zeros((n, n)) # Initialize proximity matrix
    for i in range(n):
        for j in range(n):
            if i != j:
                # Compute cosine similarity and transform to proximity
```

```

        cos_theta = np.dot(X[i], X[j]) / (np.linalg.norm(X[i]) *
np.linalg.norm(X[j]))
        P[i, j] = 1 - cos_theta
    return P

# P(X)
P = proximity_matrix(X)

# Convert matrices to pandas DataFrames for better formatting

P_df = pd.DataFrame(P, index=[f"Point {i+1}" for i in range(X.shape[0])],
                     columns=[f"Point {i+1}" for i in range(X.shape[0])])

# Print the matrices in a nicely formatted way
print("\nD(X) - Distance Matrix:")
print(D)

print("\nP(X) - Proximity Matrix:")
print(P_df.round(3)) # Round to 3 decimal places for better readability

```

*Ερώτημα Γ*

### Αρχικό Στάδιο

Ξεκινάμε με 8 μονομελή συμπλέγματα:

{1}, {2}, {3}, {4}, {5}, {6}, {7}, {8}.

Αρχικά, εντοπίζουμε την ελάχιστη τιμή εγγύτητας στον πίνακα  $P(x_i, x_j)$ . Η ελάχιστη εγγύτητα είναι  $P(2,7) = P(7,2) = 0.002$ . Συνεπώς, τα σημεία 2 και 7 ενώνονται σε ένα νέο σύμπλεγμα:

{2,7}

---

Αναζητούμε ξανά τη μέγιστη τιμή εγγύτητας. Εντοπίζουμε ότι η ελάχιστη τιμή είναι  $P(4, 6) = 0.006$ . Συνεπώς, τα σημεία 4 και 6 ενώνονται σε ένα νέο σύμπλεγμα:

{4,6}

---

Η επόμενη ελάχιστη τιμή στον πίνακα εγγύτητας είναι  $P(1, 5) = 0.008$ .. Συνεπώς, τα σημεία 1 και 5 ενώνονται:

{1,5}

---

Τώρα έχουμε τρία διμελή συμπλέγματα:  $\{2,7\}, \{4,6\}, \{1,5\}$  και δύο μονομελή:  $\{3\}, \{8\}$ . Ελέγχουμε τις νέες εγγύτητες και βρίσκουμε την ελάχιστη:

$$P(\{2,7\}, \{4,6\}) = \min P(x_2, x_4), P(x_2, x_6), P(x_7, x_4), P(x_7, x_6) = 0.010$$

Τα συμπλέγματα  $\{2,7\}$  και  $\{4,6\}$  ενώνονται σε ένα νέο σύμπλεγμα:

$$\{2,4,6,7\}$$


---

Τα συμπλέγματα είναι πλέον:  $\{1,5\}, \{2,4,6,7\}, \{3\}, \{8\}$ . Η ελάχιστη εγγύτητα τώρα βρίσκεται μεταξύ  $\{1,5\}$  και  $\{3\}$ :

$$P(\{1,5\}, \{3\}) = \min P(x_1, x_3), P(x_5, x_3) = 0.019$$

Συνεπώς, ενώνονται:

$$\{1,3,5\}$$


---

Τα συμπλέγματα είναι τώρα:  $\{1,3,5\}, \{2,4,6,7\}, \{8\}$ . Εντοπίζουμε την ελάχιστη εγγύτητα μεταξύ  $\{2,4,6,7\}$  και  $\{8\}$ :

$$P(\{2,4,6,7\}, \{8\}) = \min P(x_2, x_8), P(x_4, x_8), P(x_6, x_8), P(x_7, x_8) = 0.022$$

Συνεπώς, ενώνονται:

$$\{2,4,6,7,8\}$$


---

Απομένουν δύο συμπλέγματα:  $\{1,3,5\}$  και  $\{2,4,6,7,8\}$ . Η ελάχιστη εγγύτητα είναι:

$$\begin{aligned} & P(\{2,4,6,7,8\}, \{1,3,5\}) \\ &= \min P(x_2, x_1), P(x_2, x_3), P(x_2, x_5), P(x_4, x_1), P(x_4, x_3), P(x_4, x_5), P(x_6, x_1), P(x_6, x_3), P(x_6, x_5) \dots, \\ &= 0.035 \end{aligned}$$

Όλα τα σημεία ενώνονται σε ένα τελικό σύμπλεγμα:

$$\{1,2,3,4,5,6,7,8\}$$

Παρακάτω δίνεται ο βοηθητικός κώδικας (έτοιμη βιβλιοθήκη χρησιμοποιήθηκε) και το αντίστοιχο δενδρόγραμμα.


```
# Convert the proximity matrix to a condensed form
P_condensed = squareform(P)

# Hierarchical Clustering with Single Linkage
linkage_matrix_single = linkage(P_condensed, method='single')
```

```

# Plot dendrogram for Single Linkage
plt.figure(figsize=(10, 5))
dendrogram(linkage_matrix_single, labels=np.arange(1, X.shape[0] + 1))
plt.title('Dendrogram (Single Linkage)')
plt.xlabel('Data Points')
plt.ylabel('Proximity')
plt.show()

```



*Ερώτημα Δ*

### Αρχικό Στάδιο

Ξεκινάμε με 8 μονομελή συμπλέγματα:

$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{7\}, \{8\}$ .

Αρχικά, εντοπίζουμε την ελάχιστη τιμή εγγύτητας στον πίνακα  $P(x_i, x_j)$ . Η ελάχιστη εγγύτητα είναι  $P(2,7) = P(7,2) = 0.002$ . Συνεπώς, τα σημεία 2 και 7 ενώνονται σε ένα νέο σύμπλεγμα:

$$\{2,7\}$$


---

Αναζητούμε ξανά τη μέγιστη τιμή εγγύτητας. Εντοπίζουμε ότι η ελάχιστη τιμή είναι  $P(4,6) = 0.006$ . Συνεπώς, τα σημεία 4 και 6 ενώνονται σε ένα νέο σύμπλεγμα:

$$\{4,6\}$$


---

Η επόμενη ελάχιστη τιμή στον πίνακα εγγύτητας είναι  $P(1,5) = 0.008$ . Συνεπώς, τα σημεία 1 και 5 ενώνονται:

$$\{1,5\}$$

---

Τώρα έχουμε τρία διμελή συμπλέγματα:  $\{2,7\}, \{4,6\}, \{1,5\}$  και δύο μονομελή:  $\{3\}, \{8\}$ . Ελέγχουμε τις νέες εγγύτητες και βρίσκουμε την μέγιστη:

$$P(\{2,7\}, \{4,6\}) = \max P(x_2, x_4), P(x_2, x_6), P(x_7, x_4), P(x_7, x_6) = 0.047$$

Τα συμπλέγματα  $\{2,7\}$  και  $\{4,6\}$  ενώνονται σε ένα νέο σύμπλεγμα:

$$\{2,4,6,7\}$$

---

Τα συμπλέγματα είναι πλέον:  $\{1,5\}, \{2,4,6,7\}, \{3\}, \{8\}$ . Η μέγιστη εγγύτητα τώρα μεταξύ  $\{1,5\}$  και  $\{3\}$ :

$$P(\{1,5\}, \{3\}) = \max P(x_1, x_3), P(x_5, x_3) = 0.051$$

Συνεπώς, ενώνονται:

$$\{1,3,5\}$$

---

Τα συμπλέγματα είναι τώρα:  $\{1,3,5\}, \{2,4,6,7\}, \{8\}$ . Εντοπίζουμε τη μέγιστη εγγύτητα μεταξύ  $\{2,4,6,7\}$  και  $\{8\}$ :

$$P(\{2,4,6,7\}, \{8\}) = \max P(x_2, x_8), P(x_4, x_8), P(x_6, x_8), P(x_7, x_8) = 0.132$$

Συνεπώς, ενώνονται:

$$\{2,4,6,7,8\}$$

---

Απομένουν δύο συμπλέγματα:  $\{1,3,5\}$  και  $\{2,4,6,7,8\}$ . Η ελάχιστη εγγύτητα είναι:

$$\begin{aligned} &P(\{2,4,6,7,8\}, \{1,3,5\}) \\ &= \max P(x_2, x_1), P(x_2, x_3), P(x_2, x_5), P(x_4, x_1), P(x_4, x_3), P(x_4, x_5), P(x_6, x_1), P(x_6, x_3), P(x_6, x_5) \dots, \\ &= 0.553 \end{aligned}$$


Όλα τα σημεία ενώνονται σε ένα τελικό σύμπλεγμα:

$$\{1,2,3,4,5,6,7,8\}$$

Παρακάτω δίνεται ο βοηθητικός κώδικας (έτοιμη βιβλιοθήκη χρησιμοποιήθηκε) και το αντίστοιχο δενδρογραμμα.

```
# Hierarchical Clustering with Complete Linkage
linkage_matrix_complete = linkage(P_condensed, method='complete')

# Plot dendrogram for Complete Linkage
plt.figure(figsize=(10, 5))
dendrogram(linkage_matrix_complete, labels=np.arange(1, X.shape[0] + 1))
plt.title('Dendrogram (Complete Linkage)')
plt.xlabel('Data Points')
plt.ylabel('Proximity')
plt.show()
```



### Ερώτημα E

Παρατηρούμε ότι τα δύο δενδρογράμματα που προκύπτουν από τις μεθόδους απλού και πλήρους δεσμού είναι πανομοιότυπα. Και στις δύο περιπτώσεις, οι ομαδοποιήσεις που προκύπτουν είναι οι εξής: ένα cluster για τα σημεία  $\{3,1,5\}$  και ένα για τα σημεία  $\{2,7,4,6,8\}$ . Το γεγονός ότι οι δύο μέθοδοι οδηγούν στο ίδιο αποτέλεσμα μπορεί να αποδοθεί στη φύση των δεδομένων. Πιο συγκεκριμένα, οι αποστάσεις μεταξύ των σημείων πρέπει να είναι τέτοιες ώστε η ελάχιστη και η μέγιστη απόσταση εντός των ομάδων να είναι παρόμοιες, ώστε τόσο ο απλός όσο και ο πλήρης δεσμός να καταλήγουν σε παρόμοια ή ταυτόσημα αποτελέσματα.

a) Για  $m=1$ : Έχουμε  $\|\vec{u}_1\|=1$ , και  $\vec{u}_1^T \cdot \vec{u}_1 = 1$

Η πρόβλημα του  $\vec{x}_n$  διανομής στο  $\vec{u}_1$  μοναδικό διάνυσμα θα είναι

$$\vec{y}_n = \vec{x}_n^T \vec{u}_1$$

$$\text{Var}(\vec{y}_n) = \frac{1}{N} \sum_{n=1}^N \vec{y}_n^2 = \frac{1}{N} \sum_{n=1}^N (\vec{x}_n \cdot \vec{u}_1)^2 = \frac{1}{N} \sum_{n=1}^N (\vec{x}_n^T \vec{u}_1) \circ (\vec{x}_n^T \vec{u}_1) = \frac{1}{N} \sum_{n=1}^N \vec{u}_1^T (\vec{x}_n \circ \vec{x}_n^T) \vec{u}_1$$

$$\Rightarrow \text{Var}(\vec{y}_n) = \vec{u}_1^T \left( \frac{1}{N} \sum_{n=1}^N \vec{x}_n \cdot \vec{x}_n^T \right) \cdot \vec{u}_1 = \boxed{\vec{u}_1^T \Sigma \vec{u}_1}$$

Covariance matrix

Θέλουμε να μετρούμενο το variance, με  $\|\vec{u}_1\|=1$ . ( $\max \frac{\vec{u}_1^T \Sigma \vec{u}_1}{\|\vec{u}_1\|}$ ) με  $\vec{u}_1^T \vec{u}_1 = 1$   
Θα αξιοποιήσουμε την μέθοδο των πληθυντικών Lagrange.

Ορίζουμε συνάρτηση Lagrange:  $L(\vec{u}_1, \lambda) = \vec{u}_1^T \Sigma \vec{u}_1 - \lambda(\vec{u}_1^T \cdot \vec{u}_1 - 1)$

$$\frac{\partial L}{\partial \vec{u}_1} = 0 \Rightarrow 2 \Sigma \vec{u}_1 - 2\lambda \vec{u}_1 = 0 \Leftrightarrow \Sigma \vec{u}_1 = \lambda \vec{u}_1 \quad (1)$$

Δικτύωση:  $\frac{\partial (\vec{x}^T A \vec{x})}{\partial \vec{x}} = \vec{x}^T (A + A^T)$ , ηλ.  $\text{cov } A = \Sigma$ , ο  $\Sigma$  είναι συμετρικός όπου  $\Sigma^T = \Sigma$ .

$$\frac{\partial L}{\partial \lambda} = \vec{u}_1^T \vec{u}_1 - 1 = 0 \text{, δηλαδη σημαντική η προϋπόθεση ότι}$$

Από την (1) ~~εφαρμόζουμε την~~ θέλουμε την διάνυσμα  $\vec{u}_1$  είναι διοδιανυτικό και  $\vec{u}_1$  η αντιστοιχία ιδιοτήτων

Δεδομένου ότι θέλουμε να μετρούμενο το Var αρχαίας σημείου με μερικές ιδιότητες, θέλουμε να διαλέξουμε την μερικές ιδιότητες.

Ότι αν τιμούμε ιδιότητές της,  $\vec{u}_1, \vec{u}_2, \dots, \vec{u}_n$  τα διατηγμένα μέσα φρέσκωση στην  $(\vec{u}_1^T \vec{u}_2, \vec{u}_2^T \vec{u}_3, \dots, \vec{u}_n^T \vec{u}_1)$  (τελικά η προστιθέμενη ένα  $\vec{u}_1^T \vec{u}_1$ ). Τρέπουμε στο  $\vec{u}_1$  ως δριμύτης συνδυασμό στην ιδιότητα  $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$  (ορθογώνια). Όπου  $\vec{u}_1 = c_1 \vec{v}_1 + c_2 \vec{v}_2 + \dots + c_n \vec{v}_n \Rightarrow \vec{u}_1^T \Sigma \vec{u}_1 = c_1^2 \lambda_1 + \dots + c_n^2 \lambda_n$

Όπως μετρούμενο αυτή την τιμούσα  $c_1 = c_2 = \dots = c_n = 0$ ,  $c_1 = 1$  όπου δεν μετρούμενο είναι την μερικές ιδιότητη:  $\vec{u}_1$  (όπως αυτά συμβαίνει και με την πλήρη Lagrange)

⊗ Όπου θέλουμε να επισύρουμε σε αυτά διοδιανυτικά

B) Για  $m=2$  τιμούσια έχουμε  $\vec{y}_{n_1} = \vec{u}_1^T \vec{x}_n$  και  $\vec{y}_{n_2} = \vec{u}_2^T \vec{x}_n$

$$\text{Var}_{\text{total}} = \frac{1}{N} \sum_{n=1}^N (\vec{y}_{n_1}^2 + \vec{y}_{n_2}^2) = \frac{1}{N} \sum_{n=1}^N \vec{u}_{n_1}^T \vec{u}_{n_1} + \frac{1}{N} \vec{u}_{n_2}^T \vec{u}_{n_2} \xrightarrow[\text{Επωτ. (a)}]{\text{Όπως στο}} \vec{u}_1^T \vec{u}_1 + \vec{u}_2^T \vec{u}_2$$

Έχουμε τώρα  $\vec{u}_1^T \vec{u}_1 = \vec{u}_2^T \vec{u}_2 = 1$  και  $\vec{u}_1^T \vec{u}_2 = 0$

δυνατότητας αρθρωτικής

$$J(\vec{u}_1, \vec{u}_2, \lambda_1, \lambda_2, \mu) = \vec{u}_1^T \vec{u}_1 + \vec{u}_2^T \vec{u}_2 - \lambda_1(\vec{u}_1^T \vec{u}_1 - 1) - \lambda_2(\vec{u}_2^T \vec{u}_2 - 1) - \boxed{\mu \vec{u}_1^T \vec{u}_2}$$

$$\frac{\partial J}{\partial \lambda_1} = 0 \Rightarrow \boxed{\vec{u}_1^T \vec{u}_1 = 1}, \quad \frac{\partial J}{\partial \lambda_2} = 0 \Rightarrow \boxed{\vec{u}_2^T \vec{u}_2 = 1} \text{ και } \frac{\partial J}{\partial \mu} = 0 \Rightarrow \boxed{\vec{u}_1^T \vec{u}_2 = 0}$$

Έτσουμε ότι τις πρώτες μέρισμα.

$$\frac{\partial d}{\partial \vec{u}_1} = 0 \Leftrightarrow 2 \cdot \vec{u}_1 - 2\lambda_1 \vec{u}_1 - \mu \vec{u}_2 = 0 \Leftrightarrow \vec{u}_1 = \lambda_1 \vec{u}_1 + \frac{\mu}{2} \vec{u}_2, \text{ επειδή } u_1 \perp u_2 \text{ πρέπει,} \\ \Rightarrow \boxed{\vec{u}_1 = \lambda_1 \vec{u}_1} \quad \mu = 0$$

$$\frac{\partial d}{\partial \vec{u}_2} = 0 \Leftrightarrow 2 \vec{u}_2 - 2\lambda_2 \vec{u}_2 - \mu \vec{u}_1 = 0 \Leftrightarrow \vec{u}_2 = \lambda_2 \vec{u}_2 + \frac{\mu}{2} \vec{u}_1, \text{ } u_1 \perp u_2 \text{ υπό } \mu = 0 \\ \Rightarrow \boxed{\vec{u}_2 = \lambda_2 \vec{u}_2}$$

Άρα  $u_1, u_2$  διαδικανούμενα στη με θέση  $\lambda_1, \lambda_2$  ιδιότητες. Επειδή, μεταστρέφουμε στη διανομή  $\mu$  σα  $\lambda_1, \lambda_2$ , οπως και για  $m=1$  έτσι και στις  $\lambda_1, \lambda_2$  στα ίδια και μεταξύ τους αντίστοιχα.

Ariðstisjón: Εάν με γραπτή (a) αριθμούμε σύριγα  $c_1 = c_2 = 1$  και  $c_3 = c_4 = \dots = c_n = 0$ . Σημειώνουμε ότι  $\vec{u}_1, \vec{u}_2$  είναι διαδικανούμενα. Επομένως, δεν μπορούμε να μεταστρέψουμε στη  $\text{Var}_{\text{total}}$ , αλλα στη  $\text{Var}_{\text{partial}}$ .

Όταν δεν δινούμε περισσότερα  $m \leq 2$  έχουμε τιμούσια:  $\vec{y}_{n_i} = \vec{u}_i^T \vec{x}_n$ ,  $i=1, \dots, m$

$$\text{Var}_{\text{total}} = \sum_{i=1}^m \vec{u}_i^T \vec{u}_i, \text{ έχουμε } \vec{u}_i^T \vec{u}_i = 1 \text{ και } \vec{u}_i^T \vec{u}_j = 0, \text{ για } i \neq j$$

Lagrange dianipenon:

$$L(u_1, \dots, u_m, \lambda_1, \dots, \lambda_m, \mu_{ij}) = \sum_{i=1}^m \vec{u}_i^T \vec{\lambda} \cdot \vec{u}_i - \sum_{i=1}^m \lambda_i (\vec{u}_i^T \vec{u}_{i-1}) - \sum_{i,j} \mu_{ij} \cdot \vec{u}_i^T \vec{u}_j$$

$$\frac{\partial L}{\partial \lambda_i} = 0 \Rightarrow \boxed{\vec{u}_i^T \vec{u}_i = 1}, \quad \frac{\partial L}{\partial \mu_{ij}} = 0 \Rightarrow \boxed{\vec{u}_i^T \vec{u}_j = 0}, \quad \text{Eftorwlofikis twn tigriqiqes}$$

$$\begin{aligned} \frac{\partial L}{\partial u_i} = 0 &\Rightarrow \sum \vec{u}_i - \sum \lambda_i \vec{u}_i - \sum_{j \neq i} \mu_{ij} \vec{u}_i^T \vec{u}_j = 0 \quad \text{me } u_i \perp u_j \text{ apa } \boxed{\mu_{ij} = 0} \\ &\Rightarrow \sum \vec{u}_i = \lambda_i \vec{u}_i + \frac{1}{2} \sum_{j \neq i} \mu_{ij} \vec{u}_i^T \vec{u}_j \Rightarrow \boxed{\sum \vec{u}_i = \lambda_i \vec{u}_i} \quad \text{me } u_i \text{ idiosyncrasy me } \lambda_i \text{ idiosyncrasy} \end{aligned}$$

Kai antocedouw tis metadiwes  $\lambda_1, \dots, \lambda_m$  idiosyncrasy. Antwefin: fteriavon cou f am, me tis idiosyncrasy exwto  $c_1 = \lambda_1, c_2 = \lambda_2, \dots, c_m = \lambda_m, c_{m+1} = c_{m+2} = \dots = c_\ell = 0$

Vurtotal =  $\lambda_1 + \dots + \lambda_m$ . Tiparwou, ocan exwto  $\lambda_1, \dots, \lambda_m$  va oian pefora tis exwto am.

J) H ovanidion diaotopu twn dekopferow exwto tis givai:  $Var = \frac{1}{N} \sum_{n=1}^N \|x_n\|^2$

O. idiosyncrasy cou tis aratipoontikou twn diaotopu sti kide ovanidwra. Etwfikis ois  $\frac{1}{N} \sum_{n=1}^N \|x_n\|^2$  ovanidwra:  $Var_m = \sum_{i=1}^m \lambda_i$ . Auto ioxwsi diaotopu trace( $\vec{\lambda}$ ) =  $\sum_{i=1}^m \lambda_i = \frac{1}{N} \sum_{n=1}^N \|x_n\|^2$ , apa dia variance ois m ovanidwra:

Dwretiws to tio doxoo p twn diaotopas twn dekopferow tis "gymnvesti" atio m kópits ovanidwra givai.

$$P = \frac{Var_m}{Var} = \frac{\sum_{i=1}^m \lambda_i}{\frac{1}{N} \sum_{n=1}^N \|x_n\|^2} = N \cdot \frac{\sum_{i=1}^m \lambda_i}{\sum_{n=1}^N \|x_n\|^2}$$

## Aσύνον 2.5

a) Χαρακτηριστικός: Οδύνη και τερπυρίων του 4x4 πλέγματος (16 κανονικάτων)

$$S = \{(x,y) \mid x,y \in \{0,1,2,3\}\}$$

Εργασίες: Οι δυνατές κανονικότητες του μήναρην να μηδεί το πόρπιτ

~~$A = \{\text{Τιανώ, μισώ, απορρεψη, σεξισμός}\}$~~

Αρχηγούς:  $R: S \times A \times S \rightarrow \mathbb{R}$ , Η αρχηγός είναι σάσιμη από την κανονική κανονικότητα  $S$ , Και είναι ακανονική από την επιφένεια κανονικότητας  $S'$ .

- $R(s, a, s') = +10$  όταν  $s' = (3,3)$  (η επιφένεια μήναρην που πήρε οριστικότητα)
- $R(s, a, s') = -10$ , όταν  $s' = (2,2)$  (η " " " " " από παραβολή)
- $R(s, a, s') = -1$ , οποιαδήποτε άλλη μήναρη.

Τιμολογίας Μεταβολών:  $P(s'|s, a) = \begin{cases} 1, & \text{αν } s' \neq s \text{ (ήλιας } (3,3) \text{ ή } (2,2)) \\ 0, & \text{αλλιώς,} \\ 1, & s = s' \text{ ή } s = (3,3), (2,2) \text{ ή } a = (3,3) \rightarrow \text{οριστικότητα} \\ & \text{ή } a = (2,2) \rightarrow \text{παραβολή} \end{cases}$

Οι μήναρης σίναρην υπερθερμοποίησης, συνηθίζει να έχει παραβολή μεταβολών. Ελίξις, αν το πόρπιτ οπιστεύεται σα αίρεται μεταβολή από την μήναρην στον οπινό, το οποίο θέτει στην ιδιαίτερη μήναρην στον οπινό.


B) Επικυρώσιμη στρατηγική:

Τιμολογίας Μεταβολών

$$V^*(s) = \mathbb{E}_{s'} [r + \gamma V^*(s')] = \mathbb{E}_{s'} [R(s, a, s') + \gamma \overline{V^*(s')} ] = r_0 + \gamma \max_{s_1} r_1 + \gamma^2 \max_{s_2} r_2 + \dots$$

Όπου γενικής από την Γενικήν  $V_0$  και υποδομής γενικήν επικυρώσιμην επικυρώσιμην  $V_1$  μεταβολής την  $r_0 + \dots$  να ονταινεί από  $\mathbb{E}_{s'} [r + \gamma V^*(s')]$  (Εξιών Bellman)

γ) Με τιμολογίαν αποτελούμενην Μακριάνην από  $(0,0)$  και αν έχουμε λοοποίηση σε



αποτελούμενην από  $(0,0)$  και αν έχουμε λοοποίηση σε

μημότηρα  $y$ : Άρα θα ακολουθήσουμε διαδρομή:

$$(0,0) \rightarrow (0,1) \rightarrow (0,2) \rightarrow (0,3) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$$

$$-1 \quad -1 \quad -1 \quad -1 \quad -1 \quad -1 \quad +10$$

$$\text{Άρα } V^*(s) = r_0 + \gamma \max_{s_1} r_1 + \gamma^2 \max_{s_2} r_2 + \dots$$

$$= -1 + 0.9(-1) + 0.9^2(-1) + 0.9^3(-1) + 0.9^4(-1) + 0.9^5(-1) + 0.9^6(10) = 0.62882$$

To idio arithmetikou da briseite kai na ean anadromous zino.

δ) Egyptikoi arri ene to diakini tou exoupi stadeget. Ena ene to diakini oso (γ)

Exoupi zinw, to  $V(2,1) = r_{21} + \gamma \cdot V(2,2) = r_{21} + \gamma \cdot r_{22} = -1 + 0.9 \cdot (-1) = \boxed{-10}$

apou δtv  
vriperhi statheta metaxw